



Basic Numpy, Pytorch, Tensorflow

Dinh-Tiem Nguyen

Quang-Vinh Dinh

Abstract

Keywords: Numpy, Pytorch, Tensorflow

I. Introduction

Thế giới đang không ngừng biến đổi bởi công nghệ trí tuệ nhân tạo(AI), việc hiểu và áp dụng hiệu quả các công cụ lập trình là chìa khóa để ta khám phá công nghệ này. Ba thư viện lớn (Numpy, Pytorch và Tensorflow) đóng vai trò không thể thiếu trong quá trình phát triển công nghệ AI. Mỗi thư viện với những đặc tính riêng biệt, nhưng cùng hướng tới mục tiêu chung là tối ưu hóa quá trình xử lý dữ liệu và phát triển mô hình học máy. Bài viết này được thiết kế để cung cấp một cái nhìn cơ bản nhất về cách sử dụng cả ba thư viện này.

Trong bài viết, ta sẽ khám phá bản chất của mỗi thư viện, phân tích những điểm tương đồng và sự khác biệt về cú pháp. Ta sẽ thấy rằng, mặc dù Numpy, Pytorch và Tensorflow khác nhau bởi cú pháp, nhưng lại được xây dựng trên cùng mục đích; do đó, việc hiểu rõ một thư viện sẽ giúp ta học nhanh được 2 thư viện còn lại. Bài viết giúp chúng ta nhanh chóng tiếp cận kiến thức cơ bản nhất của ba thư viện cùng lúc.

II. Requirements

Trước khi bắt đầu sử dụng các thư viện Numpy, Pytorch và Tensorflow, ta cần tạo một môi trường ảo để quản lý các gói phụ thuộc và đảm bảo tính nhất quán của môi trường. Ta cũng có thể cài đặt trực tiếp trên hệ thống máy tính nhưng điều này không được khuyến khích vì có thể gây xung đột nếu cài nhiều phiên bản thư viện khác nhau.

II.1. Tạo môi trường với Conda

Để cài đặt Anaconda, ta có thể tải và cài đặt từ [trang chính thức của Conda](#). Sau khi cài đặt xong, ta có thể sử dụng lệnh sau để tạo một môi trường mới:

```
1 # Tạo môi trường mới với tên "my_env"  
2 conda create --name my_env
```

II.2. Numpy

Numpy thường được cài đặt mặc định trong nhiều môi trường Python, nhưng nếu ta chưa cài đặt hoặc muốn đảm bảo đang sử dụng phiên bản mới nhất, ta có thể sử dụng pip trong môi trường conda:

```
1 # Kích hoạt môi trường
2 conda activate my_env
3
4 # Cài đặt Numpy
5 pip install Numpy
```

II.3. Pytorch

Cài đặt Pytorch trong môi trường conda có thể được thực hiện như sau:

```
1 # Cài đặt Pytorch với hỗ trợ CPU
2 pip3 install torch torchvision torchaudio
```

Ta có thể chọn các phiên bản cài đặt tại [đây](#)

II.4. Tensorflow

Cài đặt Tensorflow trong môi trường conda, xem thêm hướng dẫn tại [đây](#):

```
1 # Cài đặt Tensorflow (CPU)
2 pip install "tensorflow<2.11"
```

Lưu ý: Hướng dẫn trên dành cho máy sử dụng hệ điều hành window và bộ xử lý CPU. Để sử dụng Pytorch, Tensorflow GPU, ta cần cài đặt các driver và thư viện CUDA và cuDNN tương ứng với cấu hình máy tính ta sử dụng.

Sau khi tạo môi trường và cài đặt các thư viện, ta có thể kích hoạt môi trường và bắt đầu sử dụng Numpy, Pytorch và Tensorflow trong môi trường ảo của mình.

III. Basic Numpy, Pytorch, Tensorflow

Trong quá trình tính toán, chúng ta có thể chuyển đổi dễ dàng các thư viện như ví dụ phía dưới. Ví dụ này thực hiện những hành động sau:

- Bắt đầu bằng việc tạo một mảng NumPy 1 chiều và in giá trị và kiểu dữ liệu của nó.
- Sau đó sử dụng **torch.from_numpy** để chuyển đổi mảng NumPy thành tensor PyTorch và in tensor cùng kiểu dữ liệu của nó.
- Tiếp theo Sử dụng hàm **.numpy()** của tensor PyTorch để chuyển đổi tensor thành mảng NumPy và in mảng cùng kiểu dữ liệu của nó.

Đối với Tensorflow thực hiện chuyển đổi tương tự.

```

1 import numpy as np
2 import torch
3 import tensorflow as tf
4
5 # Tạo một NumPy array
6 array1D = np.array([1, 2, 3])
7 print("Numpy array 1D:\n", array1D, type(array1D))
8
9 # Chuyển đổi mảng NumPy thành tensor PyTorch
10 arr_tensor_torch = torch.from_numpy(array1D)
11 print("Chuyển đổi mảng NumPy thành tensor PyTorch:\n", arr_tensor_torch, type(
    arr_tensor_torch))
12 # Chuyển đổi tensor PyTorch thành mảng NumPy
13 tensor_torch_arr = arr_tensor_torch.numpy()
14 print("Chuyển đổi tensor PyTorch thành mảng NumPy:\n", tensor_torch_arr, type(
    tensor_torch_arr))
15
16 # Chuyển đổi mảng NumPy thành tensor TensorFlow
17 arr_tensor_tf = tf.convert_to_tensor(array1D)
18 print("Chuyển đổi mảng NumPy thành tensor TensorFlow:\n", arr_tensor_tf, type(
    arr_tensor_tf))
19 # Chuyển đổi tensor TensorFlow thành mảng NumPy
20 tensor_tf_arr = arr_tensor_tf.numpy()
21 print("Chuyển đổi tensor TensorFlow thành mảng NumPy:\n", tensor_tf_arr, type(
    tensor_tf_arr))

```

```

===== Output =====
Numpy array 1D:
 [1 2 3] <class 'numpy.ndarray'>
Chuyển đổi mảng NumPy thành tensor PyTorch:
 tensor([1, 2, 3], dtype=torch.int32) <class 'torch.Tensor'>
Chuyển đổi tensor PyTorch thành mảng NumPy:
 [1 2 3] <class 'numpy.ndarray'>
Chuyển đổi mảng NumPy thành tensor TensorFlow:
 tf.Tensor([1 2 3], shape=(3,), dtype=int32) <class 'tensorflow.python.framework.ops.
    EagerTensor'>
Chuyển đổi tensor TensorFlow thành mảng NumPy:
 [1 2 3] <class 'numpy.ndarray'>
=====

```

III.1. Tạo một array, tensor

Array trong Numpy và Tensor trong các thư viện như Pytorch hoặc Tensorflow là những thành phần nền tảng cốt lõi cho việc tính toán của các thư viện này. Trong đó:

- **Array trong Numpy** là một cấu trúc dữ liệu đa chiều mạnh mẽ, giúp lưu trữ và thực hiện các phép toán toán học trên dữ liệu số. Array có thể là mảng một chiều (vector), mảng hai chiều (ma trận), hoặc nhiều chiều hơn.
- **Tensor trong Pytorch và Tensorflow** là một cấu trúc dữ liệu nhiều chiều, tương tự như array trong Numpy, nhưng được thiết kế để tương thích với học sâu và tính toán song song,

đặc biệt là trên các thiết bị như GPU và TPU. Trong Pytorch và Tensorflow, tensors là đơn vị cơ bản để lưu trữ và xử lý dữ liệu.

Có nhiều cách khác nhau để ta tạo array hay tensor. Cách đầu tiên, ta tạo chúng từ list-kiểu dữ liệu quen thuộc trong Python.

```

1 import numpy as np
2 import torch
3 import tensorflow as tf
4
5 # Tạo một danh sách 1 chiều
6 list_1D = [1, 2, 3, 4, 5, 6, 7, 8, 9]
7
8 # Tạo một mảng 1 chiều từ danh sách
9 arr_1D = np.array(list_1D)
10 print("Mảng 1 chiều NumPy:\n", arr_1D, type(arr_1D))
11
12 # Tạo một tensor PyTorch từ danh sách
13 tensor_1D_pt = torch.tensor(list_1D)
14 print("Tensor PyTorch 1 chiều:\n", tensor_1D_pt)
15
16 # Tạo một tensor TensorFlow từ danh sách
17 tensor_1D_tf = tf.convert_to_tensor(list_1D)
18 print("Tensor TensorFlow 1 chiều:\n", tensor_1D_tf)

```

```

===== Output =====
Mảng 1 chiều NumPy:
[1 2 3 4 5 6 7 8 9] <class 'numpy.ndarray'>
Tensor PyTorch 1 chiều:
tensor([1, 2, 3, 4, 5, 6, 7, 8, 9])
Tensor TensorFlow 1 chiều:
tf.Tensor([1 2 3 4 5 6 7 8 9], shape=(9,), dtype=int32)
=====

```

Ví dụ trên thực hiện tạo array, tensor từ một list Python. Để tạo array chúng ta dùng cú pháp **np.array(list_1D)**, với pytorch thì ta dùng **torch.tensor(list_1D)** và với Tensorflow ta dùng

tf.convert_to_tensor(list_1D) hoặc **tf.constant(list_1D)**. Khi làm việc với cấu trúc dữ liệu array hay tensor, ta có thể kiểm tra thuộc tính của chúng thông qua một số cú pháp sau:

- **shape** là thuộc tính cho biết kích thước của mảng hoặc tensor, tức là số phần tử trong mỗi chiều của chúng.
- **dtype** là thuộc tính cho biết kiểu dữ liệu của các phần tử trong mảng hoặc tensor.
- **type** cho biết kiểu của đối tượng mảng hoặc tensor.
- **device** chỉ có ở trong Pytorch và Tensorflow, và nó cho biết nơi lưu trữ tensor, có thể là CPU hoặc GPU.

Ví dụ Numpy:

```

1 # NumPy code
2 import numpy as np
3 # Tạo một danh sách 2 chiều
4 list_2D = [[1, 2, 3], [4, 5, 6], [7, 8, 9]]
5 # Tạo một mảng 2 chiều
6 arr_2D = np.array(list_2D)
7 # Kiểm tra hình dạng, kiểu dữ liệu, loại của mảng
8 print("Hình dạng của mảng: ", arr_2D.shape)
9 print("Kiểu dữ liệu của mảng: ", arr_2D.dtype)
10 print("Loại của mảng: ", type(arr_2D))
11 print("Mảng:\n", arr_2D)

```

```

===== Output =====
Hình dạng của mảng: (3, 3)
Kiểu dữ liệu của mảng: int32
Loại của mảng: <class 'numpy.ndarray'>
Mảng:
[[1 2 3]
 [4 5 6]
 [7 8 9]]
=====

```

Trong đoạn mã Numpy trên, chúng ta bắt đầu bằng việc tạo ra một danh sách 2D (**list_2D**) đại diện cho một ma trận có 3 hàng và 3 cột. Sau đó, chúng ta sử dụng Numpy để chuyển danh sách này thành một mảng 2 chiều (**arr_2D**). Dòng mã tiếp theo sử dụng các hàm tích hợp trong Numpy để in ra hình dạng (shape), kiểu dữ liệu (dtype), và kiểu của mảng (type). Cuối cùng, chúng ta in ra nội dung của mảng để kiểm tra kết quả

Ví dụ Pytorch:

```

1 # PyTorch code
2 import torch
3
4 # Tạo một danh sách 2 chiều
5 list_2D = [[1, 2, 3], [4, 5, 6], [7, 8, 9]]
6 # Tạo một tensor 2 chiều
7 tensor_2D_pt = torch.tensor(list_2D)
8
9 # Kiểm tra hình dạng, kiểu dữ liệu, loại, thiết bị lưu trữ của tensor
10 print("Hình dạng của tensor: ", tensor_2D_pt.shape)
11 print("Kiểu dữ liệu của tensor: ", tensor_2D_pt.dtype)
12 print("Loại của tensor: ", type(tensor_2D_pt))
13 print("Thiết bị lưu trữ của tensor: ", tensor_2D_pt.device)
14 print("Tensor:\n", tensor_2D_pt)

```

```

===== Output =====
Hình dạng của tensor: torch.Size([3, 3])
Kiểu dữ liệu của tensor: torch.int64
Loại của tensor: <class 'torch.Tensor'>

```

```
Thiết bị lưu trữ của tensor:  cpu
```

```
Tensor:
```

```
tensor([[1, 2, 3],
        [4, 5, 6],
        [7, 8, 9]])
```

```
=====
```

Trong đoạn mã Pytorch trên, chúng ta bắt đầu bằng cách tạo một danh sách 2D (**list_2D**) đại diện cho ma trận 3x3. Sau đó, chúng ta sử dụng Pytorch để chuyển đổi danh sách này thành tensor 2 chiều (**tensor_2D_pt**).

Dòng mã tiếp theo sử dụng các thuộc tính tích hợp trong Pytorch để in ra hình dạng (shape), kiểu dữ liệu (dtype), kiểu của tensor (type), và thiết bị lưu trữ của tensor (device). Cuối cùng, chúng ta in ra nội dung của tensor để kiểm tra kết quả.

Ví dụ Tensorflow:

```
1 import tensorflow as tf
2
3 # Tạo một danh sách 2 chiều
4 list_2D = [[1, 2, 3], [4, 5, 6], [7, 8, 9]]
5 # Tạo một tensor 2 chiều từ danh sách
6 tensor_2D_tf = tf.convert_to_tensor(list_2D)
7
8 # Kiểm tra hình dạng, kiểu dữ liệu, loại, thiết bị mà tensor được lưu trữ
9 print("Hình dạng của tensor: ", tensor_2D_tf.shape)
10 print("Kiểu dữ liệu của tensor: ", tensor_2D_tf.dtype)
11 print("Loại của tensor: ", type(tensor_2D_tf))
12 print("Thiết bị mà tensor được lưu trữ: ", tensor_2D_tf.device)
13 print(tensor_2D_tf)
```

```
===== Output =====
```

```
Hình dạng của tensor:  (3, 3)
```

```
Kiểu dữ liệu của tensor:  <dtype: 'int32'>
```

```
Loại của tensor:  <class 'tensorflow.python.framework.ops.EagerTensor'>
```

```
Thiết bị mà tensor được lưu trữ:  /job:localhost/replica:0/task:0/device:CPU:0
```

```
tf.Tensor(
```

```
[[1 2 3]
```

```
 [4 5 6]
```

```
 [7 8 9]], shape=(3, 3), dtype=int32)
```

```
=====
```

Tương tự như Pytorch, trong đoạn mã Tensorflow trên, chúng ta bắt đầu bằng cách tạo một danh sách 2D (**list_2D**) đại diện cho ma trận 3x3. Sau đó, chúng ta sử dụng Tensorflow để chuyển đổi danh sách này thành một tensor 2 chiều (**tensor_2D_tf**) bằng hàm **tf.convert_to_tensor()**.

Dòng mã tiếp theo sử dụng các thuộc tính tích hợp trong Tensorflow để in ra hình dạng (shape), kiểu dữ liệu (dtype), kiểu của tensor (type), và thiết bị lưu trữ của tensor (device). Cuối cùng, chúng ta in ra nội dung của tensor để kiểm tra kết quả.

III.2. Update an array, tensor

Cho một mảng đa chiều (như Numpy array hoặc Pytorch tensor) biểu diễn bằng A với i là chỉ số hàng và j là chỉ số cột, giá trị của một phần tử tại hàng i và cột j được biểu diễn là A_{ij} . Để cập nhật giá trị của A_{ij} thành một giá trị mới V , chúng ta sử dụng phép gán: $A_{ij} = V$.

Ví Dụ: Giả sử có một mảng A :

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

Giả sử chỉ số hàng i cột j của mảng bắt đầu từ 0, chúng ta muốn cập nhật giá trị của phần tử ở hàng thứ 1, cột thứ 1 (A_{11}) thành 10:

$$A_{11} = 10$$

Mảng sau khi cập nhật sẽ trở thành:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 10 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

Mô tả này áp dụng cho cả Numpy array và Pytorch tensor, nói chung là mọi mảng đa chiều trong lĩnh vực đại số tuyến tính.

Sau đây là ví dụ cập nhật giá trị của phần tử tại vị trí $[1][1]$ trong mảng numpy array.

```
1 # NumPy code
2 import numpy as np
3 # Tạo một danh sách 2 chiều
4 list_2D = [[1, 2, 3], [4, 5, 6], [7, 8, 9]]
5 # Tạo một mảng 2 chiều
6 arr_2D = np.array(list_2D)
7 # Cập nhật phần tử tại hàng 1, cột 1
8 arr_2D[1][1] = 10
9 print("Mảng sau khi cập nhật:\n", arr_2D)
```

```
===== Output =====
Mảng sau khi cập nhật:
[[ 1  2  3]
 [ 4 10  6]
 [ 7  8  9]]
=====
```

Đối với mảng tensor trong Pytorch thì cú pháp cập nhật giá trị của phần tử trong mảng giống trong Numpy.

```

1 # PyTorch code
2 import torch
3 # Tạo một danh sách 2 chiều
4 list_2D = [[1, 2, 3], [4, 5, 6], [7, 8, 9]]
5 # Tạo một tensor 2 chiều
6 tensor_2D_pt = torch.tensor(list_2D)
7 # Cập nhật phần tử tại hàng 1, cột 1
8 tensor_2D_pt[1][1] = 10
9 print("Tensor sau khi cập nhật:\n", tensor_2D_pt)

```

```

===== Output =====
Tensor sau khi cập nhật:
  tensor([[ 1,  2,  3],
          [ 4, 10,  6],
          [ 7,  8,  9]])
=====

```

Đối với tensor trong Tensorflow, ta không thể cập nhật trực tiếp giá trị trên một tensor trong Tensorflow vì tensors trong Tensorflow được thiết kế để là không thay đổi (immutable). Khi tạo một tensor, giá trị của nó được xác định và không thể thay đổi sau khi đã được tạo. Điều này giúp tối ưu hóa hiệu suất tính toán và quản lý bộ nhớ, đặc biệt quan trọng trong các tác vụ học sâu và tính toán song song. Tuy nhiên, có thể sử dụng các biến (**tf.Variable**) trong Tensorflow để lưu trữ và cập nhật giá trị. **tf.Variable** là một loại đối tượng đặc biệt được thiết kế để cho phép sự thay đổi giá trị. Nó rất hữu ích trong quá trình học, cho phép cập nhật giá trị của các tham số mô hình thông qua quá trình huấn luyện.

Đây là ví dụ về cách tạo và cập nhật một **tf.Variable**:

```

1 import tensorflow as tf
2
3 # Tạo một biến
4 var = tf.Variable(initial_value=[1.0, 2.0, 3.0], dtype=tf.float32)
5
6 # Cập nhật giá trị của biến
7 var.assign([4.0, 5.0, 6.0])
8 print("Biến sau khi cập nhật giá trị:\n", var)
9
10 # Hoặc cập nhật giá trị dựa trên giá trị hiện tại
11 var.assign_add([1.0, 1.0, 1.0])
12 print("Biến sau khi cập nhật giá trị dựa trên giá trị hiện tại:\n", var)

```

```

===== Output =====
Biến sau khi cập nhật giá trị:
<tf.Variable 'Variable:0' shape=(3,) dtype=float32, numpy=array([4., 5., 6.], dtype=
float32)>
Biến sau khi cập nhật giá trị dựa trên giá trị hiện tại:
<tf.Variable 'Variable:0' shape=(3,) dtype=float32, numpy=array([5., 6., 7.], dtype=
float32)>
=====

```


Trong ví dụ trên, **var** là một **tf.Variable** mà ta có thể cập nhật giá trị của nó. **assign** và **assign_add** là các hàm cho phép ta thay đổi giá trị của **tf.Variable**.

III.3. Một số cách tạo array, tensor

Có một số cách để nhanh chóng tạo ra các array với giá trị, kích thước khác nhau. Trong các cách dưới đây, tên hàm trong cả ba thư viện hầu hết giống nhau. Ta sẽ nhận thấy hàm sử dụng của Numpy và Pytorch giống nhau hoàn toàn, còn Tensorflow sẽ có một số khác biệt nhỏ.

a) *zeros*

zeros là hàm thực hiện chức năng tạo array toàn giá trị 0 với đầu vào là kích thước và kiểu dữ liệu ta muốn. Cả 3 thư viện này đều sử dụng hàm trên, với cú pháp tương tự nhau, hãy cùng xem các ví dụ dưới đây:

Ví dụ sau tạo array với kích thước (3, 4), đối với thư viện Numpy sử dụng cú pháp **np.zeros**

```
1 # Numpy code
2 import numpy as np
3
4 # Tạo array toàn số 0
5 arr_zeros = np.zeros((3, 4))
6 print(arr_zeros)
```

```
===== Output =====
[[0. 0. 0. 0.]
 [0. 0. 0. 0.]
 [0. 0. 0. 0.]]
=====
```

Tương tự như thư viện Numpy, Pytorch sử dụng cú pháp ***torch.zeros***

```
1 #Pytorch code
2 import torch
3
4 # Tạo tensor toàn số 0
5 tensor_zeros = torch.zeros((3, 4))
6 print(tensor_zeros)
```

```
===== Output =====
tensor([[0., 0., 0., 0.],
        [0., 0., 0., 0.],
        [0., 0., 0., 0.]])
=====
```

Tương tự, Tensorflow sử dụng cú pháp ***tf.zeros***

```
1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo tensor toàn số 0
5 tensor_zeros = tf.zeros((3, 4))
6 print(tensor_zeros)
```

```
===== Output =====
[[0. 0. 0. 0.]
 [0. 0. 0. 0.]
 [0. 0. 0. 0.]], shape=(3, 4), dtype=float32)
```

Nhìn chung, hàm ***zeros*** chủ yếu dùng để khởi tạo mảng hoặc tensor với các giá trị 0, thường được dùng trong quá trình xây dựng các mô hình máy học và thực hiện các phép toán số học.

b) *ones*

Tương tự với ***zeros***, ***ones*** tạo mảng chứa toàn số 1 với đầu vào là kích thước bất kỳ.

```
1 # Numpy code
2 import numpy as np
3
4 # Tạo array toàn số 1
5 arr_ones = np.ones((3, 4))
6 print(arr_ones)
```

```
===== Output =====
[[1. 1. 1. 1.]
 [1. 1. 1. 1.]
```

```
[1. 1. 1. 1.]
```

Đối với Pytorch và Tensorflow, ta sử dụng hàm **ones** hoàn toàn tương tự như ví dụ với Numpy.

c) *full*

Hàm này giúp chúng ta tạo array với phần tử là giá trị chỉ định, đầu vào của hàm *full* gồm kích thước array và giá trị hằng số muốn tạo.

Ví dụ sau tạo array với kích thước (3, 4), giá trị hằng số là 5. Đối với thư viện Numpy sử dụng cú pháp *np.full*

```
1 # Numpy code
2 import numpy as np
3
4 # Tạo array toàn số 5
5 arr_full = np.full((3, 4), 5)
6 print(arr_full)
```

```
===== Output =====
[[5 5 5 5]
 [5 5 5 5]
 [5 5 5 5]]
=====
```

Tương tự như thư viện Numpy, Pytorch sử dụng cú pháp *torch.full*

```
1 #Pytorch code
2 import torch
3
4 # Tạo tensor toàn số 5
5 tensor_full = torch.full((3, 4), 5)
6 print(tensor_full)
```

```
===== Output =====
tensor([[5, 5, 5, 5],
        [5, 5, 5, 5],
        [5, 5, 5, 5]])
=====
```

Khác với hai thư viện trên, Tensorflow sử dụng hàm **fill** để tạo một constant tensor với giá trị được chỉ định. Dưới đây là cách sử dụng:

```
1 # Tensorflow code
2 import tensorflow as tf
```

```

3
4 # Tạo tensor toàn số 5
5 tensor_full = tf.fill((3, 4), 5)
6 print(tensor_full)

```

```

===== Output =====
tf.Tensor(
[[5 5 5 5]
 [5 5 5 5]
 [5 5 5 5]], shape=(3, 4), dtype=int32)
=====

```

Tóm lại, hàm **full** với Numpy, Pytorch hay **fill** với Tensorflow giúp tạo array hoặc tensor với giá trị được chỉ định, có ích khi ta cần khởi tạo các cấu trúc dữ liệu với giá trị đồng nhất.

Trong Numpy, hàm **arange** được sử dụng để tạo một mảng chứa dãy số có giá trị tăng dần với khoảng cách cố định. Cú pháp như sau:

```

1 # Numpy code
2 import numpy as np
3
4 # Tạo array trong khoảng [0, 10), bước nhảy 1
5 arr_arange = np.arange(10)
6 print(arr_arange)

```

```

===== Output =====
[0 1 2 3 4 5 6 7 8 9]
=====

```

Trong PyTorch, để tạo tensor chứa dãy số, ta sử dụng hàm **torch.arange**:

```

1 #Pytorch code
2 import torch
3
4 # Tạo tensor trong khoảng [0, 10), bước nhảy 1
5 tensor_arange = torch.arange(10)
6 print(tensor_arange)

```

```

===== Output =====
tensor([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
=====

```

Trong Tensorflow, ta có thể sử dụng hàm **tf.range** để thực hiện chức năng tương tự:

```

1 # Tensorflow code
2 import tensorflow as tf
3

```

```

4 # Tạo tensor trong khoảng [0, 10), bước nhảy 1
5 tensor_arange = tf.range(10)
6 print(tensor_arange)

```

```

===== Output =====
tf.Tensor([0 1 2 3 4 5 6 7 8 9], shape=(10,), dtype=int32)
=====

```

arange (hoặc **range** trong Tensorflow) rất hữu ích khi ta muốn tạo ra một dãy số tăng dần với các giá trị cách đều nhau, giúp tạo mảng hoặc tensor có dãy số liên tục dễ dàng hơn.

e) *eye*

Hàm **eye** được sử dụng để tạo ma trận đơn vị, tức là một ma trận vuông có tất cả các phần tử trên đường chéo chính có giá trị 1, còn lại là 0. Cách sử dụng như sau:

```

1 # Numpy code
2 import numpy as np
3
4 # Tạo array với đường chéo chính là 1, còn lại là 0
5 arr_eye = np.eye(3)
6 print(arr_eye)

```

```

===== Output =====
[[1. 0. 0.]
 [0. 1. 0.]
 [0. 0. 1.]]
=====

```

Trong Pytorch, để tạo tensor đơn vị, ta sử dụng hàm **torch.eye**:

```

1 #Pytorch code
2 import torch
3
4 # Tạo tensor với đường chéo chính là 1, còn lại là 0
5 tensor_eye = torch.eye(3)
6 print(tensor_eye)

```

```

===== Output =====
tensor([[1., 0., 0.],
        [0., 1., 0.],
        [0., 0., 1.]])
=====

```

Trong Tensorflow, hàm **eye** cũng được sử dụng để tạo constant tensor đơn vị:

```

1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo tensor với đường chéo chính là 1, còn lại là 0
5 tensor_eye = tf.eye(3)
6 print(tensor_eye)

```

```

===== Output =====
tf.Tensor(
[[1. 0. 0.]
 [0. 1. 0.]
 [0. 0. 1.]], shape=(3, 3), dtype=float32)
=====

```

Hàm **eye** giúp tạo ma trận hoặc tensor đơn vị, đặc biệt hữu ích trong nhiều ứng dụng toán học và xử lý dữ liệu.

f) *random*

Numpy cung cấp một loạt các hàm để tạo các mảng chứa giá trị ngẫu nhiên. Trong ví dụ dưới đây, **np.random.rand** tạo mảng với các giá trị ngẫu nhiên trong khoảng $[0.0, 1.0)$ với hình dạng (shape) được chỉ định. Với **np.random.randint** dùng để tạo mảng với các số nguyên ngẫu nhiên. Cách sử dụng chúng như sau:

```

1 #Numpy code
2 import numpy as np
3
4 # Đặt seed để đảm bảo kết quả ngẫu nhiên có thể tái tạo được
5 np.random.seed(2024)
6
7 # Tạo một mảng với các giá trị ngẫu nhiên trong khoảng [0, 1) với kích thước (3, 4)
8 arr_rand = np.random.rand(3, 4)
9 print("Mảng ngẫu nhiên trong khoảng [0, 1):\n", arr_rand)
10
11 # Tạo một mảng với các giá trị ngẫu nhiên trong khoảng [-10, 10)
12 arr_randint = np.random.randint(-10, 10, size=(3, 4))
13 print("Mảng ngẫu nhiên trong khoảng [-10, 10):\n", arr_randint)

```

```

===== Output =====
Mảng ngẫu nhiên trong khoảng [0, 1):
[[0.58801452 0.69910875 0.18815196 0.04380856]
 [0.20501895 0.10606287 0.72724014 0.67940052]
 [0.4738457  0.44829582 0.01910695 0.75259834]]
Mảng ngẫu nhiên trong khoảng [-10, 10):
[[ 5  1 -3  8]
 [-1 -4  0 -9]
 [-5  9 -6 -2]]
=====

```

Trong Pytorch, các hàm tương tự cũng có sẵn thông qua module torch. **torch.rand** tạo

tensor với các giá trị ngẫu nhiên từ phân phối đều trong khoảng $[0.0, 1.0)$, **torch.randint** dùng để tạo tensor với các số nguyên ngẫu nhiên trong một khoảng cụ thể.

```

1 # Pytorch code
2 import torch
3
4 # Thiết lập seed để đảm bảo kết quả ngẫu nhiên có thể tái tạo được
5 torch.manual_seed(2024)
6
7 # Tạo tensor với các giá trị ngẫu nhiên trong khoảng [0, 1) với kích thước (3, 4)
8 tensor_rand = torch.rand((3, 4))
9 print("Tensor ngẫu nhiên trong khoảng [0, 1):\n", tensor_rand)
10
11 # Tạo tensor với các giá trị ngẫu nhiên trong khoảng [-10, 10)
12 tensor_randint = torch.randint(-10, 10, size=(3, 4))
13 print("Tensor ngẫu nhiên trong khoảng [-10, 10):\n", tensor_randint)

```

```

===== Output =====
Tensor ngẫu nhiên trong khoảng [0, 1):
tensor([[0.5317, 0.8313, 0.9718, 0.1193],
        [0.1669, 0.3495, 0.2150, 0.6201],
        [0.4849, 0.7492, 0.1521, 0.5625]])
Tensor ngẫu nhiên trong khoảng [-10, 10):
tensor([[ 1,  8,  0, -2],
        [-9, -10, -9,  0],
        [-3, -7, -4,  8]])
=====

```

Trong Tensorflow, ta cũng có các hàm tương tự trong module tf. Sử dụng **tf.random.uniform** để tạo constant tensor với các giá trị ngẫu nhiên trong khoảng $[0.0, 1.0)$, và sử dụng **tf.random.uniform** để tạo constant tensor với các số nguyên ngẫu nhiên trong một khoảng cụ thể.

```

1 #TensorFlow code
2 import tensorflow as tf
3
4 # Thiết lập seed để đảm bảo kết quả ngẫu nhiên có thể tái tạo được
5 tf.random.set_seed(2024)
6
7 # Tạo tensor với các giá trị ngẫu nhiên trong khoảng [0, 1)
8 tensor_rand = tf.random.uniform((3, 4))
9 print("Tensor ngẫu nhiên trong khoảng [0, 1):\n", tensor_rand)
10
11 # Tạo tensor với các giá trị ngẫu nhiên trong khoảng [-10, 10)
12 tensor_randint = tf.random.uniform((3, 4), minval=-10, maxval=10, dtype=tf.dtypes.int32)
13 print("Tensor ngẫu nhiên trong khoảng [-10, 10):\n", tensor_randint)

```

```

===== Output =====
Tensor ngẫu nhiên trong khoảng [0, 1):

```

```
tf.Tensor(
[[0.90034294 0.19453335 0.36069036 0.66361904]
 [0.76605344 0.2159369 0.6261736 0.07380784]
 [0.22062695 0.934368 0.93327904 0.69267046]], shape=(3, 4), dtype=float32)
Tensor ngẫu nhiên trong khoảng [-10, 10):
tf.Tensor(
[[-3 -7 9 3]
 [ 2 -5 -3 -5]
 [ 4 -3 -3 5]], shape=(3, 4), dtype=int32)
=====
```

Các hàm này giúp việc tạo dữ liệu ngẫu nhiên trở nên dễ dàng trong quá trình phát triển mô hình máy học và thực nghiệm số liệu.

III.4. Một số hàm quan trọng

a) *clip*

Hàm **clip** có chức năng giới hạn giá trị của một array hoặc tensor trong một khoảng xác định, đồng thời giữ nguyên cấu trúc dữ liệu ban đầu.

Trong Numpy, hàm này được sử dụng để cắt giá trị của một mảng vào khoảng xác định, cách sử dụng như sau:

```
1 # Numpy code
2 import numpy as np
3
4 # Thiết lập seed để đảm bảo kết quả ngẫu nhiên có thể tái tạo được
5 np.random.seed(2024)
6
7 # Tạo một array với các giá trị ngẫu nhiên trong khoảng [-10, 10) với kích thước (3, 3)
8 arr_rand = np.random.randint(-10, 10, (3, 3))
9 print("Mảng ngẫu nhiên trong khoảng [-10, 10):\n", arr_rand)
10
11 # Sử dụng hàm clip để cắt các giá trị nằm ngoài khoảng [3, 8]
12 arr_clip = np.clip(arr_rand, a_min=3, a_max=8)
13 print("Mảng sau khi được cắt trong khoảng [3, 8):\n", arr_clip)
```

```
===== Output =====
Mảng ngẫu nhiên trong khoảng [-10, 10):
[[ -2 -10 -10]
 [ -6  -1  -9]
 [ -7  0  -8]]
Mảng sau khi được cắt trong khoảng [3, 8]:
[[3 3 3]
 [3 3 3]
 [3 3 3]]
=====
```

Trong ví dụ trên, ta thiết lập **seed** giúp đảm bảo rằng kết quả ngẫu nhiên có thể được tái tạo. Tiếp theo, sử dụng **np.random.randint** để tạo một array với các giá trị ngẫu nhiên trong

khoảng $[-10, 10]$ với kích thước $(3, 3)$. Sau đó **np.clip** được sử dụng để cắt các giá trị trong array sao cho chúng không vượt qua khoảng $[3, 8]$. Tức là giá trị nào nhỏ hơn 3 thì sẽ gán bằng 3, giá trị nào lớn hơn 8 sẽ gán bằng 8, các giá trị trong khoảng $[3, 8]$ thì giữ nguyên.

Trong Pytorch, ta có thể sử dụng **clamp** hoặc **clip** đều được, vì trong Pytorch **clip** là tên bí danh hoặc có thể hiểu là tên viết tắt của **clamp**. Dưới đây là ví dụ:

```
1 #Pytorch code
2 import torch
3
4 # Thiết lập seed để đảm bảo kết quả ngẫu nhiên có thể tái tạo được
5 torch.manual_seed(2024)
6
7 # Tạo một tensor với các giá trị ngẫu nhiên trong khoảng [-10, 10) với kích thước (3,
   4)
8 tensor_rand = torch.randint(-10, 10, size=(3, 4))
9 print("Tensor ngẫu nhiên trong khoảng [-10, 10):\n", tensor_rand)
10
11 # Sử dụng hàm clamp để cắt các giá trị nằm ngoài khoảng [3, 8]
12 tensor_clip = torch.clamp(tensor_rand, min=3, max=8)
13 print("Tensor sau khi được cắt trong khoảng [3, 8):\n", tensor_clip)
```

```
===== Output =====
Tensor ngẫu nhiên trong khoảng [-10, 10):
tensor([[ 2,  0, -6, -10],
        [-7, -10,  0,  1],
        [ 3,  9,  7, -6]])
Tensor sau khi được cắt trong khoảng [3, 8]:
tensor([[3, 3, 3, 3],
        [3, 3, 3, 3],
        [3, 8, 7, 3]])
=====
```

Trong Tensorflow, ta có thể sử dụng hàm **tf.clip_by_value** để giới hạn giá trị của tensor:

```
1
2 # Tensorflow code
3 import tensorflow as tf
4
5 # Thiết lập seed để đảm bảo kết quả ngẫu nhiên có thể tái tạo được
6 tf.random.set_seed(2024)
7
8 # Tạo một tensor với các giá trị ngẫu nhiên trong khoảng [-10, 10) với kích thước (3,
   4)
9 tensor_random = tf.random.uniform((3, 4), minval=-10, maxval=10, dtype=tf.int32)
10 print("Tensor ngẫu nhiên trong khoảng [-10, 10):\n", tensor_random)
11
12 # Sử dụng hàm clip_by_value để cắt các giá trị nằm ngoài khoảng [3, 8]
13 tensor_clip = tf.clip_by_value(tensor_random, clip_value_min=3, clip_value_max=8)
14 print("Tensor sau khi được cắt trong khoảng [3, 8):\n", tensor_clip)
```

```

===== Output =====
Tensor ngẫu nhiên trong khoảng [-10, 10):
tf.Tensor(
[[ -6 -2  0 -2]
 [  4  4 -9  3]
 [  7  1  2 -5]], shape=(3, 4), dtype=int32)
Tensor sau khi được cắt trong khoảng [3, 8]:
tf.Tensor(
[[3 3 3 3]
 [4 4 3 3]
 [7 3 3 3]], shape=(3, 4), dtype=int32)
=====

```

Hàm **clip** (hoặc **clamp** trong Pytorch) rất hữu ích khi ta muốn đảm bảo rằng các giá trị trong mảng hoặc tensor không vượt quá một khoảng cụ thể, giúp kiểm soát và chuẩn hóa dữ liệu, đặc biệt trong quá trình tiền xử lý dữ liệu cho mô hình máy học.

b) *hstack*

Hàm **hstack** được sử dụng để nối (hoặc "stack") các mảng hoặc tensors theo chiều ngang (theo trục cột).

Ví dụ sử dụng **hstack** được sử dụng để nối các mảng theo chiều ngang trong Numpy:

```

1 #Numpy code
2 import numpy as np
3
4 # Tạo hai mảng
5 arr_1 = np.array([1, 2, 3])
6 arr_2 = np.array([4, 5, 6])
7
8 # Nối hai mảng theo trục ngang (axis=0)
9 arr_3 = np.hstack((arr_1, arr_2))
10
11 # In kết quả
12 print("Mảng 1:\n", arr_1)
13 print("Mảng 2:\n", arr_2)
14 print("Mảng sau khi nối theo trục ngang:\n", arr_3)

```

```

===== Output =====
[1 2 3 4 5 6]
=====

```

Trong Pytorch sử dụng tương tự như Numpy với cú pháp **torch.hstack**.

```
1 #Pytorch code
2 import torch
3
4 # Tạo hai tensor
5 tensor_1 = torch.tensor([1, 2, 3])
6 tensor_2 = torch.tensor([4, 5, 6])
7
8 # Nối hai tensor theo trục ngang
9 tensor_3 = torch.hstack((tensor_1, tensor_2))
10 print("Tensor 1:\n", tensor_1)
11 print("Tensor 2:\n", tensor_2)
12 print("Tensor sau khi nối theo trục ngang:\n", tensor_3)
```

```
===== Output =====
Tensor 1:
  tensor([1, 2, 3])
Tensor 2:
  tensor([4, 5, 6])
Tensor sau khi nối theo trục ngang:
tensor([1, 2, 3, 4, 5, 6])
=====
```

Hàm **hstack** là một công cụ linh hoạt khi ta cần nối các dữ liệu theo chiều ngang, thích hợp trong các bước tiền xử lý dữ liệu hoặc xây dựng các đặc trưng cho mô hình máy học. Trong Tensorflow không có hàm **hstack**, tuy nhiên ta có thể sử dụng hàm **concatenate** sẽ được trình bày ở phần tiếp theo.

c) *vstack*

Hàm **vstack** được sử dụng để nối (hoặc "stack") các mảng hoặc tensors theo chiều dọc (theo trục hàng).

Trong Numpy, **vstack** được sử dụng để nối các mảng theo chiều dọc. Ví dụ:

```
1 # Numpy code
2 import numpy as np
3 # Tạo hai array
4 arr_1 = np.array([1, 2, 3])
5 arr_2 = np.array([4, 5, 6])
6 # Nối hai array theo chiều dọc
7 arr_3 = np.vstack((arr_1, arr_2))
8 # In kết quả
9 print("Array 1:\n", arr_1)
10 print("Array 2:\n", arr_2)
11 print("Array sau khi nối theo chiều dọc:\n", arr_3)
```

```

===== Output =====
Array 1:
 [1 2 3]
Array 2:
 [4 5 6]
Array sau khi nối theo chiều dọc:
 [[1 2 3]
  [4 5 6]]
=====

```

```

1 #Pytorch code
2 import torch
3 # Tạo hai tensor
4 tensor_1 = torch.tensor([1, 2, 3])
5 tensor_2 = torch.tensor([4, 5, 6])
6 # Nối hai tensor theo chiều dọc bằng cách sử dụng torch.vstack
7 tensor_3 = torch.vstack((tensor_1, tensor_2))
8 # In kết quả
9 print("Tensor 1:\n", tensor_1)
10 print("Tensor 2:\n", tensor_2)
11 print("Tensor sau khi nối theo chiều dọc:\n", tensor_3)

```

```

===== Output =====
Tensor 1:
 tensor([1, 2, 3])
Tensor 2:
 tensor([4, 5, 6])
Tensor sau khi nối theo chiều dọc:
 tensor([[1, 2, 3],
        [4, 5, 6]])
=====

```

Tóm lại, hàm **vstack** là một công cụ hữu ích khi ta cần nối các dữ liệu theo chiều dọc, thích hợp trong việc xây dựng các tập dữ liệu hoặc chuẩn bị đầu vào cho mô hình máy học. Tuy nhiên trong Tensorflow không có hàm **vstack** nhưng ta có thể sử dụng **concatenate** sẽ được trình bày ở phần tiếp theo.

d) *concatenate*

Hàm **concatenate** được sử dụng để nối các mảng hoặc tensors theo một chiều cụ thể.

Trong Numpy, **concatenate** được sử dụng để nối các mảng theo chiều ngang và dọc. Ví dụ:

```

1 # Numpy code
2 import numpy as np
3 # Tạo hai array 2D
4 arr_1 = np.array([[1, 2, 3], [4, 5, 6]])
5 arr_2 = np.array([[7, 8, 9], [10, 11, 12]])
6 # Nối hai array theo chiều dọc axis = 0
7 arr_3 = np.concatenate((arr_1, arr_2), axis=0)

```

```

8 # Nối hai array theo chiều ngang axis = 1
9 arr_4 = np.concatenate((arr_1, arr_2), axis=1)
10 # In kết quả
11 print("Array 1:\n", arr_1)
12 print("Array 2:\n", arr_2)
13 print("Nối theo chiều dọc (axis=0):\n", arr_3)
14 print("Nối theo chiều ngang (axis=1):\n", arr_4)

```

```

===== Output =====
Array 1:
[[1 2 3]
 [4 5 6]]
Array 2:
[[ 7  8  9]
 [10 11 12]]
Nối theo chiều dọc (axis=0):
[[ 1  2  3]
 [ 4  5  6]
 [ 7  8  9]
 [10 11 12]]
Nối theo chiều ngang (axis=1):
[[ 1  2  3  7  8  9]
 [ 4  5  6 10 11 12]]
=====

```

Trong ví dụ trên ta sử dụng `np.concatenate` để nối hai mảng theo chiều dọc (`axis=0`) và chiều ngang (`axis=1`). Trong đó `arr_1` và `arr_2` là hai mảng 2D được tạo bằng NumPy. Tiếp theo, `arr_3` được tạo bằng cách nối `arr_1` và `arr_2` theo chiều dọc (`axis=0`), nghĩa là nối theo hàng. Cuối cùng `arr_4` được tạo bằng cách nối `arr_1` và `arr_2` theo chiều ngang (`axis=1`), nghĩa là nối theo cột.

Trong Pytorch, để thực hiện nối tensors theo một chiều cụ thể, ta sử dụng `torch.cat` với tham số `dim`, trong đó `dim = 1` sẽ nối theo chiều ngang, `dim = 0` sẽ nối theo chiều dọc:

```

1 #Pytorch code
2 import torch
3 # Tạo hai tensor 2D
4 tensor_1 = torch.tensor([[1, 2, 3], [4, 5, 6]])
5 tensor_2 = torch.tensor([[7, 8, 9], [10, 11, 12]])
6 # Nối hai tensor theo chiều dọc axis = 0
7 tensor_3 = torch.cat((tensor_1, tensor_2), dim=0)
8 # Nối hai tensor theo chiều ngang axis = 1
9 tensor_4 = torch.cat((tensor_1, tensor_2), dim=1)
10 # In kết quả
11 print("Tensor 1:\n", tensor_1)
12 print("Tensor 2:\n", tensor_2)
13 print("Nối theo chiều dọc (axis=0):\n", tensor_3)
14 print("Nối theo chiều ngang (axis=1):\n", tensor_4)

```

```

===== Output =====
Tensor 1:
  tensor([[1, 2, 3],
         [4, 5, 6]])
Tensor 2:
  tensor([[ 7,  8,  9],
         [10, 11, 12]])
Nối theo chiều dọc (axis=0):
  tensor([[ 1,  2,  3],
         [ 4,  5,  6],
         [ 7,  8,  9],
         [10, 11, 12]])
Nối theo chiều ngang (axis=1):
  tensor([[ 1,  2,  3,  7,  8,  9],
         [ 4,  5,  6, 10, 11, 12]])
=====

```

Trong Tensorflow, **concatenate** tương đương với **tf.concat** với tham số **axis** để chỉ định kết nối theo chiều nào:

```

1 # Tensorflow code
2 import tensorflow as tf
3 # Tạo hai tensor 2D
4 tensor_1 = tf.constant([[1, 2, 3], [4, 5, 6]])
5 tensor_2 = tf.constant([[7, 8, 9], [10, 11, 12]])
6 # Nối hai tensor theo chiều dọc axis = 0
7 tensor_3 = tf.concat((tensor_1, tensor_2), axis=0)
8 # Nối hai tensor theo chiều ngang axis = 1
9 tensor_4 = tf.concat((tensor_1, tensor_2), axis=1)
10 # In kết quả
11 print("Tensor 1:\n", tensor_1)
12 print("Tensor 2:\n", tensor_2)
13 print("Nối theo chiều dọc (axis=0):\n", tensor_3)
14 print("Nối theo chiều ngang (axis=1):\n", tensor_4)

```

```

===== Output =====
Tensor 1:
  tf.Tensor(
  [[1 2 3]
   [4 5 6]], shape=(2, 3), dtype=int32)
Tensor 2:
  tf.Tensor(
  [[ 7  8  9]
   [10 11 12]], shape=(2, 3), dtype=int32)
Nối theo chiều dọc (axis=0):
  tf.Tensor(
  [[ 1  2  3]
   [ 4  5  6]
   [ 7  8  9]
   [10 11 12]], shape=(4, 3), dtype=int32)
Nối theo chiều ngang (axis=1):

```

```
tf.Tensor(
[[ 1  2  3  7  8  9]
 [ 4  5  6 10 11 12]], shape=(2, 6), dtype=int32)
=====
```

Hàm **concatenate** là một công cụ linh hoạt, cho phép ta nối các mảng hoặc tensors theo bất kỳ trục nào mà ta mong muốn.

e) *Thêm nhiều chiều vào array, tensor.*

Khi thực hiện tính toán với array, tensor, chúng ta sẽ thường xuyên phải điều chỉnh số chiều của chúng. Để thêm một chiều mới, chúng ta sử dụng **newaxis** hoặc **expand_exis**.

Ví dụ sau đây thực hiện thêm một chiều mới vào array sử dụng **newaxis**:

```
1 #Numpy code
2 import numpy as np
3 # Tạo một array 1D
4 arr_1 = np.array([1, 2, 3])
5 # 1D -> 2D
6 arr_2 = arr_1[np.newaxis, :]
7 # 2D -> 5D
8 arr_3 = arr_2[np.newaxis, :, np.newaxis, :, np.newaxis]
9 print("array 1: ", arr_1, arr_1.shape)
10 print("array 2: ", arr_2, arr_2.shape)
11 print("array 3:\n ", arr_3, arr_3.shape)
```

```
===== Output =====
array 1:  [1 2 3] (3,)
array 2:  [[1 2 3]] (1, 3)
array 3:
[[[[[1]
      [2]
      [3]]]]] (1, 1, 1, 3, 1)
=====
```

Trong ví dụ trên, ta tạo một mảng 1D có giá trị [1, 2, 3]. Tiếp theo ta sử dụng **np.newaxis** để thêm một chiều mới ở vị trí 0, chuyển từ mảng 1D thành mảng 2D. Cuối cùng ta dùng **np.newaxis** để thêm nhiều chiều mới, chuyển từ mảng 2D thành mảng 5D. Các chiều mới được thêm vào ở vị trí 0, 2, và 4.

Ở đây, dấu ":" thể hiện chiều của array cũ, dấu hai chấm đầu tiên là chiều thứ nhất, dấu hai chấm thứ hai là chiều thứ 2 của array cũ. Ta có thể đặt dấu hai chấm này ở các vị trí khác nhau, tùy thuộc vào mục đích tạo array mới. "**np.newaxis**" là chiều mới ta muốn tạo, có thể đặt ở các vị trí khác nhau, ta cũng có thể thay thế nó bằng "**None**" hoặc "...".

Ngoài ra ta cũng có thể sử dụng cách thứ hai, **np.expand_dims** để thêm chiều mới cho array.

```

1 # Numpy code
2 import numpy as np
3 # Tạo một array 1D
4 arr_1 = np.array([1, 2, 3])
5 # Thêm chiều mới, chuyển từ 1D -> 2D
6 arr_2 = np.expand_dims(arr_1, axis=0)
7 # Thêm nhiều chiều mới, chuyển từ 2D -> 5D
8 arr_3 = np.expand_dims(arr_2, axis=(0, 2, 4))
9 # In kết quả
10 print("array 1:", arr_1, arr_1.shape)
11 print("array 2:", arr_2, arr_2.shape)
12 print("array 3:\n", arr_3, arr_3.shape)

```

```

===== Output =====
array 1: [1 2 3] (3,)
array 2: [[1 2 3]] (1, 3)
array 3:
[[[[[1
      [2]
      [3]]]]] (1, 1, 1, 3, 1)
=====

```

Trong Pytorch, Tensorflow, cách thêm chiều cũng thực hiện tương tự. Dưới đây là ví dụ Pytorch:

```

1 #Pytorch code
2 import torch
3 # Tạo một tensor 1D
4 tensor_1 = torch.tensor([1, 2, 3])
5 # Thêm chiều mới, chuyển từ 1D -> 2D
6 tensor_2 = tensor_1[None, :]
7 # Thêm nhiều chiều mới, chuyển từ 2D -> 5D
8 tensor_3 = tensor_2[None, :, None, :, None]
9 # In kết quả
10 print("tensor 1:", tensor_1, tensor_1.shape)
11 print("tensor 2:", tensor_2, tensor_2.shape)
12 print("tensor 3:\n", tensor_3, tensor_3.shape)

```

```

=====
tensor 1: tensor([1, 2, 3]) torch.Size([3])
tensor 2: tensor([[1, 2, 3]]) torch.Size([1, 3])
tensor 3:
tensor([[[[[1,
            [2],
            [3]]]]]]) torch.Size([1, 1, 1, 3, 1])
=====

```


Ví dụ Tensorflow:

```
1 #TensorFlow code
2 import tensorflow as tf
3 # Tạo một tensor 1D
4 tensor_1 = tf.constant([1, 2, 3])
5 # Thêm chiều mới, chuyển từ 1D -> 2D
6 tensor_2 = tf.expand_dims(tensor_1, axis=0)
7 # Thêm nhiều chiều mới, chuyển từ 2D -> 5D
8 tensor_3 = tensor_2[None, :, None, :, None]
9 # In kết quả
10 print("tensor 1:", tensor_1, tensor_1.shape)
11 print("tensor 2:", tensor_2, tensor_2.shape)
12 print("tensor 3:\n", tensor_3, tensor_3.shape)
```

```
===== Output =====
tensor 1: tf.Tensor([1 2 3], shape=(3,), dtype=int32) (3,)
tensor 2: tf.Tensor([[1 2 3]], shape=(1, 3), dtype=int32) (1, 3)
tensor 3:
  tf.Tensor(
[[[[[1
      [2
      [3]]]], shape=(1, 1, 1, 3, 1), dtype=int32) (1, 1, 1, 3, 1)
=====
```

f) *reshape*

reshape là một hàm được sử dụng để thay đổi hình dạng của một array hoặc tensor mà không làm thay đổi dữ liệu bên trong nó. Hình dạng mới được chỉ định thông qua tham số của hàm **reshape**. Trong ví dụ sau, ta sẽ sử dụng **reshape** để giảm chiều array, tensor:

```
1 # Numpy code
2 import numpy as np
3 # Tạo một array 2D
4 arr_2D = np.array([[1, 2, 3], [4, 5, 6]])
5 # Chuyển từ 2D -> 1D
6 arr_1D = np.reshape(arr_2D, newshape=(6, ))
7 print("array 2D:\n", arr_2D, arr_2D.shape)
8 print("array 1D:\n", arr_1D, arr_1D.shape)
```

```
===== Output =====
array 2D:
[[1 2 3]
 [4 5 6]] (2, 3)
array 1D:
[1 2 3 4 5 6] (6,)
=====
```

Trong ví dụ trên, ta tạo một mảng 2D có 2 hàng và 3 cột. Sử dụng **np.reshape** để thay đổi hình dạng của mảng từ 2D thành 1D với hình dạng mới là (6,), nghĩa là một mảng có 6 phần tử. Ở đây $6 = 2 \times 3$, bằng với số phần tử của mảng cũ, ta cần lưu ý khi thay đổi shape thì cần đảm bảo số lượng phần tử không được thay đổi khi **reshape**. Với Tensorflow, Pytorch cũng thực hiện tương tự.

III.5. Indexing

a) *Slicing*

Slicing là một cách để trích xuất một phần của array, tensor dựa trên các chỉ số hoặc các điều kiện. Điều này cho phép ta lấy ra các phần tử theo các quy luật cụ thể, giúp thao tác dữ liệu dễ dàng hơn.

Trong Numpy, cú pháp để thực hiện slicing là:

```
1 array[axis n row:column, axis n-1 row:column,..., axis 0 row:column, axis 1 row:column
   ]
```

ví dụ:

```
1 # Import thư viện Numpy
2 import numpy as np
3 # Tạo mảng 2D
4 array_2d = np.array([[1, 2, 3], [4, 5, 6]])
5 # Slicing mảng tại row = 0, column = 1
```

```

6 # Giữ nguyên số chiều của mảng
7 sliced_array_1 = array_2d[0:1, 1:2]
8 print("sliced_array_1 (Giữ nguyên số chiều):")
9 print(sliced_array_1)
10 # Giảm số chiều của mảng
11 sliced_array_2 = array_2d[0, 1:2]
12 print("\nsliced_array_2 (Giảm số chiều):")
13 print(sliced_array_2)
14 # Giảm số chiều của mảng
15 sliced_array_3 = array_2d[0, 1]
16 print("\nsliced_array_3 (Giảm số chiều):")
17 print(sliced_array_3)
18 # Lấy toàn bộ mảng
19 sliced_array_4 = array_2d[:, :]
20 print("\nsliced_array_4 (Giữ nguyên số chiều):")
21 print(sliced_array_4)

```

```

===== Output =====
sliced_array_1 (Giữ nguyên số chiều):
[[2]]

sliced_array_2 (Giảm số chiều):
[2]

sliced_array_3 (Giảm số chiều):
2

sliced_array_4 (Giữ nguyên số chiều):
[[1 2 3]
 [4 5 6]]
=====

```

Trong ví dụ trên là các cách ta thực hiện slicing array, ở đây có hiện tượng giảm số chiều của mảng xuất hiện khi ta trích xuất một phần nhỏ của mảng thông qua slicing và chỉ giữ lại một số chiều của nó.

Ở trường hợp đầu tiên `sliced_array_1 = array_2d[0:1, 1:2]`, ta đang trích xuất một phần của mảng bằng cách chỉ định slicing cho cả hai chiều (hàng và cột). Kết quả là một mảng 2D với số chiều không thay đổi.

Trường hợp thứ hai `sliced_array_2 = array_2d[0, 1:2]`, ta đang trích xuất một hàng (0) và một phần của cột (từ 1 đến 1). Kết quả là một mảng 1D, và số chiều của mảng đã giảm xuống.

Tương tự như `sliced_array_2`, trường hợp `sliced_array_3 = array_2d[0, 1]` ta chỉ đang trích xuất một phần nhỏ của mảng, nên kết quả là một mảng 0D (véc-tơ). Trong Numpy, mảng 0D còn được gọi là scalar.

Trong trường hợp cuối, ta lấy toàn bộ mảng bằng cách không chỉ định slicing cho bất kỳ chiều nào cả. Kết quả là một mảng 2D và số chiều không thay đổi.

Quy tắc thực hiện slicing trong Numpy cũng áp dụng cho tensor trong Pytorch và Tensorflow. Ví dụ trong Pytorch:

```
1 # Pytorch code
2 import torch
3
4 # Tạo tensor 2D
5 tensor_2d = torch.tensor([[1, 2, 3], [4, 5, 6]])
6
7 # Slicing tensor tại vị trí row= 0, column = 1
8 # Giữ nguyên số chiều của tensor
9 sliced_tensor_1 = tensor_2d[0:1, 1:2]
10 print("sliced_tensor_1 (Giữ nguyên số chiều):")
11 print(sliced_tensor_1)
12
13 # Giảm số chiều của tensor
14 sliced_tensor_2 = tensor_2d[0, 1:2]
15 print("\nsliced_tensor_2 (Giảm số chiều):")
16 print(sliced_tensor_2)
17
18 # Giảm số chiều của tensor
19 sliced_tensor_3 = tensor_2d[0, 1]
20 print("\nsliced_tensor_3 (Giảm số chiều):")
21 print(sliced_tensor_3)
22
23 # Lấy toàn bộ tensor
24 sliced_tensor_4 = tensor_2d[:, :]
25 print("\nsliced_tensor_4 (Giữ nguyên số chiều):")
26 print(sliced_tensor_4)
```

```
===== Output =====
sliced_tensor_1 (Giữ nguyên số chiều):
tensor([[2]])

sliced_tensor_2 (Giảm số chiều):
tensor([2])

sliced_tensor_3 (Giảm số chiều):
tensor(2)

sliced_tensor_4 (Giữ nguyên số chiều):
tensor([[1, 2, 3],
        [4, 5, 6]])
=====
```

Ví dụ trong Tensorflow:

```

1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo tensor 2D
5 tensor_2d = tf.constant([[1, 2, 3], [4, 5, 6]])
6
7 # Slicing tensor tại vị trí row = 0, column = 1
8 # Giữ nguyên số chiều của tensor
9 sliced_tensor_1 = tensor_2d[0:1, 1:2]
10 print("sliced_tensor_1 (Giữ nguyên số chiều):")
11 print(sliced_tensor_1)
12
13 # Giảm số chiều của tensor
14 sliced_tensor_2 = tensor_2d[0, 1:2]
15 print("\nsliced_tensor_2 (Giảm số chiều):")
16 print(sliced_tensor_2)
17
18 # Giảm số chiều của tensor
19 sliced_tensor_3 = tensor_2d[0, 1]
20 print("\nsliced_tensor_3 (Giảm số chiều):")
21 print(sliced_tensor_3)
22
23 # Lấy toàn bộ tensor
24 sliced_tensor_4 = tensor_2d[:, :]
25 print("\nsliced_tensor_4 (Giữ nguyên số chiều):")
26 print(sliced_tensor_4)

```

```

===== Output =====
sliced_tensor_1 (Giữ nguyên số chiều):
tf.Tensor([[2]], shape=(1, 1), dtype=int32)

sliced_tensor_2 (Giảm số chiều):
tf.Tensor([2], shape=(1,), dtype=int32)

sliced_tensor_3 (Giảm số chiều):
tf.Tensor(2, shape=(), dtype=int32)

sliced_tensor_4 (Giữ nguyên số chiều):
tf.Tensor(
[[1 2 3]
 [4 5 6]], shape=(2, 3), dtype=int32)
=====

```

Tùy thuộc vào mục đích mà ta có thể lựa chọn cách slice khác nhau.

b) Truy xuất row, column

Để truy cập một cột(column) hoặc một hàng(row) từ một array, tensor 2D trong Numpy, Pytorch và Tensorflow có thể được thực hiện bằng cách sử dụng indexing. Dưới đây là ví dụ và giải thích cách thực hiện:

Ví dụ thư viện Numpy:

```

1 # Numpy code
2 import numpy as np
3
4 # Tạo mảng 2D
5 arr_2d = np.array([[1, 2, 3],
6                   [4, 5, 6],
7                   [7, 8, 9]])
8
9 # Hai cách để lấy hàng 1
10 # Cách 1: giảm số chiều của mảng
11 row_1_arr_1 = arr_2d[1, :]
12 print("row_1_arr_1 (Giảm số chiều):", row_1_arr_1)
13
14 # Cách 2: giữ nguyên số chiều của mảng
15 row_1_arr_2 = arr_2d[1:2, :]
16 print("row_1_arr_2 (Giữ nguyên số chiều):", row_1_arr_2)
17
18 # Hai cách để lấy cột 2
19 # Cách 1: giảm số chiều của mảng
20 column_2_arr_1 = arr_2d[:, 2]
21 print("\ncolumn_2_arr_1 (Giảm số chiều):\n", column_2_arr_1)
22
23 # Cách 2: giữ nguyên số chiều của mảng
24 column_2_arr_2 = arr_2d[:, 2:3]
25 print("\ncolumn_2_arr_2 (Giữ nguyên số chiều):\n", column_2_arr_2)

```

```

===== Output =====
row_1_arr_1 (Giảm số chiều): [4 5 6]
row_1_arr_2 (Giữ nguyên số chiều): [[4 5 6]]

column_2_arr_1 (Giảm số chiều):
[3 6 9]

column_2_arr_2 (Giữ nguyên số chiều):
[[3]
 [6]
 [9]]
=====

```

Trong ví dụ trên, chúng ta có một mảng hai chiều ('**arr_2d**') và chúng ta thực hiện một số thao tác để lấy dữ liệu từ hàng và cột cụ thể của mảng:

- Lấy hàng 1: Chúng ta sử dụng hai cách khác nhau để lấy hàng thứ hai của mảng ('[4, 5, 6]'). Cách đầu tiên giảm số chiều của mảng, trong khi cách thứ hai giữ nguyên số chiều.
- Lấy cột 2: Chúng ta sử dụng hai cách khác nhau để lấy cột thứ ba của mảng ('[3, 6, 9]' hoặc '[[3], [6], [9]]'). Cách đầu tiên giảm số chiều của mảng, trong khi cách thứ hai giữ nguyên số chiều.

Ví dụ thư viện Pytorch, thực hiện tương tự như Numpy:

```

1 # Pytorch code
2 import torch
3
4 # Tạo tensor 2D
5 tensor_2d = torch.tensor([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
6 # Hai cách để lấy hàng 1
7 # Cách 1: giảm số chiều của tensor
8 row_1_tensor_1 = tensor_2d[1, :]
9 print("row_1_tensor_1 (Giảm số chiều):", row_1_tensor_1)
10 # Cách 2: giữ nguyên số chiều của tensor
11 row_1_tensor_2 = tensor_2d[1:2, :]
12 print("row_1_tensor_2 (Giữ nguyên số chiều):", row_1_tensor_2)
13 # Hai cách để lấy cột 2
14 # Cách 1: giảm số chiều của tensor
15 column_2_tensor_1 = tensor_2d[:, 2]
16 print("\ncolumn_2_tensor_1 (Giảm số chiều):\n", column_2_tensor_1)
17 # Cách 2: giữ nguyên số chiều của tensor
18 column_2_tensor_2 = tensor_2d[:, 2:3]
19 print("\ncolumn_2_tensor_2 (Giữ nguyên số chiều):\n", column_2_tensor_2)

```

```

===== Output =====
row_1_tensor_1 (Giảm số chiều): tensor([4, 5, 6])
row_1_tensor_2 (Giữ nguyên số chiều): tensor([[4, 5, 6]])

column_2_tensor_1 (Giảm số chiều):
tensor([3, 6, 9])

column_2_tensor_2 (Giữ nguyên số chiều):
tensor([[3],
        [6],
        [9]])
=====

```

```

1 # Tensorflow code
2 import tensorflow as tf
3 # Tạo tensor 2D
4 tensor_2d = tf.constant([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
5 # Hai cách để lấy hàng 1
6 # Cách 1: giảm số chiều của tensor
7 row_1_tensor_1 = tensor_2d[1, :]
8 print("row_1_tensor_1 (Giảm số chiều):", row_1_tensor_1)
9 # Cách 2: giữ nguyên số chiều của tensor
10 row_1_tensor_2 = tensor_2d[1:2, :]
11 print("row_1_tensor_2 (Giữ nguyên số chiều):", row_1_tensor_2)
12 # Hai cách để lấy cột 2
13 # Cách 1: giảm số chiều của tensor
14 column_2_tensor_1 = tensor_2d[:, 2]
15 print("\ncolumn_2_tensor_1 (Giảm số chiều):\n", column_2_tensor_1)
16 # Cách 2: giữ nguyên số chiều của tensor

```

```
17 column_2_tensor_2 = tensor_2d[:, 2:3]
18 print("\ncolumn_2_tensor_2 (Giữ nguyên số chiều):\n", column_2_tensor_2)
```

```
===== Output =====
row_1_tensor_1 (Giảm số chiều): tf.Tensor([4 5 6], shape=(3,), dtype=int32)
row_1_tensor_2 (Giữ nguyên số chiều): tf.Tensor([[4 5 6]], shape=(1, 3), dtype=int32)

column_2_tensor_1 (Giảm số chiều):
  tf.Tensor([3 6 9], shape=(3,), dtype=int32)

column_2_tensor_2 (Giữ nguyên số chiều):
  tf.Tensor(
[[3]
 [6]
 [9]], shape=(3, 1), dtype=int32)
=====
```

Trong cả ba thư viện, ta có thể sử dụng phép indexing với dấu hai chấm (":") để chọn tất cả các phần tử trong một chiều của mảng hoặc tensor. Để truy cập một cột, ta giữ nguyên chiều hàng và chỉ định chỉ số của cột. Để truy cập một hàng, ta giữ nguyên chiều cột và chỉ định chỉ số của hàng.

c) *Boolean indices*

Boolean indices (hoặc boolean indexing) là một cách để lấy hoặc lọc các phần tử từ một mảng dựa trên một mảng boolean có cùng hình dạng. Mảng boolean này được gọi là mask, và nó được sử dụng để chọn các phần tử tương ứng từ mảng gốc.

```

1 # Import thư viện Numpy
2 import numpy as np
3 # Tạo mảng 2D
4 array_2d = np.array([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
5 # Lấy các phần tử có giá trị lớn hơn 5
6 boolean_mask = array_2d > 5
7 filtered_result = array_2d[boolean_mask]
8 # In kết quả
9 print("Mảng 2D ban đầu:\n", array_2d)
10 print("\n Boolean mask:\n", boolean_mask)
11 print("\n Các phần tử lớn hơn 5:\n", filtered_result)

```

```

===== Output =====
Mảng 2D ban đầu:
[[1 2 3]
 [4 5 6]
 [7 8 9]]

Boolean mask:
[[False False False]
 [False False  True]
 [ True  True  True]]

Các phần tử lớn hơn 5:
[6 7 8 9]
=====

```

Trong ví dụ trên, **boolean_mask** được tạo ra bằng cách kiểm tra xem mỗi phần tử của arr có lớn hơn 5 hay không. Kết quả là một mảng **boolean_mask** với các giá trị True hoặc False. Sau đó, **boolean_mask** được sử dụng để lọc các phần tử tương ứng từ arr, chỉ giữ lại những phần tử có giá trị True.

Tương tự, cả Pytorch và Tensorflow cũng hỗ trợ boolean indexing. Quy trình là giống nhau như trong Numpy Ví dụ Pytorch:

```

1 # Pytorch code
2 import torch
3
4 # Tạo tensor 2D
5 tensor_2d = torch.tensor([[1, 2, 3],
6                             [4, 5, 6],
7                             [7, 8, 9]])
8
9 # Lấy các phần tử có giá trị lớn hơn 5
10 boolean_mask = tensor_2d > 5

```

```
11 filtered_result = tensor_2d[boolean_mask]
12
13 # In kết quả
14 print("Tensor 2D ban đầu:\n", tensor_2d)
15 print("\n Boolean mask:\n", boolean_mask)
16 print("\nCác phần tử lớn hơn 5:\n", filtered_result)
```

```
===== Output =====
Tensor 2D ban đầu:
tensor([[1, 2, 3],
        [4, 5, 6],
        [7, 8, 9]])

Boolean mask:
tensor([[False, False, False],
        [False, False,  True],
        [ True,  True,  True]])

Các phần tử lớn hơn 5:
tensor([6, 7, 8, 9])
=====
```

Ví dụ Tensorflow:

```

1 # Tensorflow code
2 import tensorflow as tf
3 # Tạo tensor 2D
4 tensor_2d = tf.constant([[1, 2, 3],
5                           [4, 5, 6],
6                           [7, 8, 9]])
7 # Lấy các phần tử có giá trị lớn hơn 5
8 boolean_mask = tensor_2d > 5
9 filtered_result = tf.boolean_mask(tensor_2d, boolean_mask)
10 # In kết quả
11 print("Tensor 2D ban đầu:\n", tensor_2d)
12 print("\n Boolean mask:\n", boolean_mask)
13 print("\nCác phần tử lớn hơn 5:\n", filtered_result)

```

```

===== Output =====
Tensor 2D ban đầu:
tf.Tensor(
[[1 2 3]
 [4 5 6]
 [7 8 9]], shape=(3, 3), dtype=int32)
Boolean mask:
tf.Tensor(
[[False False False]
 [False False  True]
 [ True  True  True]], shape=(3, 3), dtype=bool)
Các phần tử lớn hơn 5:
tf.Tensor([6 7 8 9], shape=(4,), dtype=int32)
=====

```

III.6. Các phép tính trên array, tensor

Trong phần này, chúng ta sẽ tìm hiểu về các phép tính cơ bản nhưng thật sự quan trọng khi làm việc với array, tensor. Chúng ta sẽ tạm thời quên đi vòng for và sẽ thấy được sức mạnh tính toán của những thư viện này thật sự kinh ngạc.

a) *Addition*

Chúng ta đã quá quen với các phép tính cộng, trừ, nhân, chia vì hầu hết mọi ngày ta đều sử dụng nó. Chúng ta biết về cách tính tuần tự, và gặp khó khăn khi đối mặt với số lượng tính toán lớn. Thư viện Numpy, Pytorch, Tensorflow được xây dựng để giải quyết vấn đề trên, chúng hỗ trợ việc tính toán song song, tức là thực hiện các phép tính đồng thời. Trước khi bắt đầu với các ví dụ thì ta hãy xem lại định nghĩa về phép cộng: Cho hai số a và b , phép cộng được biểu diễn bằng ký hiệu '+' và kết quả của phép cộng là tổng của a và b , thường được ký hiệu là $a + b$. Đối với array và tensor thì phép cộng giữa chúng được thực hiện theo cùng một nguyên tắc cơ bản, là phép cộng element-wise (theo từng phần tử). Phép cộng này được định nghĩa như sau: Cho hai mảng (array) A và B cùng kích thước, phép cộng giữa chúng ($A + B$) tạo ra một mảng

mới C , với mỗi phần tử C_i được tính bằng cách cộng phần tử A_i với phần tử B_i .

$$C_i = A_i + B_i$$

Trong các ví dụ dưới đây, ta thực hiện phép cộng các array, tensor bằng cách sử dụng toán tử "+" hoặc hàm `add()`.

Ví dụ với Numpy, phép cộng giữa hai mảng có cùng kích thước là việc thực hiện phép cộng giữa các phần tử tương ứng của chúng.

```

1 # Numpy code
2 import numpy as np
3 # Tạo hai array 1D
4 arr_1 = np.array([1, 2, 3, 4])
5 arr_2 = np.array([5, 6, 7, 8])
6 # Thực hiện phép cộng hai array
7 # Cách 1: Sử dụng toán tử '+'
8 arr_add_1 = arr_1 + arr_2
9 # Cách 2: Sử dụng hàm np.add()
10 arr_add_2 = np.add(arr_1, arr_2)
11 # In ra màn hình
12 print(f"arr_1 = \n{arr_1}")
13 print(f"arr_2 = \n{arr_2}")
14 print("arr_1 + arr_2")
15 print(f"arr_add_1 = \n{arr_add_1}")
16 print(f"arr_add_2 = \n{arr_add_2}")

```

```

===== Output =====
arr_1 =
[1 2 3 4]
arr_2 =
[5 6 7 8]
arr_1 + arr_2
arr_add_1 =
[ 6  8 10 12]
arr_add_2 =
[ 6  8 10 12]
=====

```

Kết quả thực hiện phép cộng sẽ là một array mới là [5, 7, 9], với mỗi phần tử là tổng của các phần tử tương ứng trong arr1 và arr2.

Tương tự, chúng ta có thể sử dụng toán tử "+" và hàm add() trong thư viện Pytorch và Tensorflow:

```

1 #Pytorch code
2 import torch
3 # Tạo hai tensor 1D
4 tensor_1 = torch.tensor([1, 2, 3, 4])
5 tensor_2 = torch.tensor([5, 6, 7, 8])
6 # Thực hiện phép cộng hai tensor
7 # Cách 1: Sử dụng toán tử '+'
8 tensor_add_1 = tensor_1 + tensor_2
9 # Cách 2: Sử dụng hàm torch.add()
10 tensor_add_2 = torch.add(tensor_1, tensor_2)
11 # In ra màn hình
12 print(f"tensor_1 = \n{tensor_1}")
13 print(f"tensor_2 = \n{tensor_2}")
14 print(f"tensor_1 + tensor_2")
15 print(f"tensor_add_1 = \n{tensor_add_1}")
16 print(f"tensor_add_2 = \n{tensor_add_2}")

```

```

===== Output =====
tensor_1 =
tensor([1, 2, 3, 4])
tensor_2 =
tensor([5, 6, 7, 8])
tensor_1 + tensor_2
tensor_add_1 =
tensor([ 6,  8, 10, 12])
tensor_add_2 =
tensor([ 6,  8, 10, 12])
=====

```

```

1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo hai tensor 1D
5 tensor_1 = tf.constant([1, 2, 3, 4])
6 tensor_2 = tf.constant([5, 6, 7, 8])
7
8 # Thực hiện phép cộng hai tensor
9 # Cách 1: Sử dụng toán tử '+'
10 tensor_add_1 = tensor_1 + tensor_2
11 # Cách 2: Sử dụng hàm tf.add()
12 tensor_add_2 = tf.add(tensor_1, tensor_2)
13
14 print(f"tensor_1 = \n{tensor_1}")
15 print(f"tensor_2 = \n{tensor_2}")
16 print(f"tensor_1 + tensor_2")
17 print(f"tensor_add_1 = \n{tensor_add_1}")
18 print(f"tensor_add_2 = \n{tensor_add_2}")

```

```

===== Output =====
tensor_1 =
[1 2 3 4]
tensor_2 =
[5 6 7 8]
tensor_1 + tensor_2
tensor_add_1 =
[ 6  8 10 12]
tensor_add_2 =
[ 6  8 10 12]
=====

```

Từ các ví dụ trên, ta có thể thấy phép cộng array, tensor có tính chất sau: Phép cộng array, tensor là một phép toán element-wise, tức là mỗi phần tử trong kết quả được tính toán dựa trên các phần tử tương ứng của các array, tensor gốc. Điều này giúp thực hiện các phép toán một cách hiệu quả trên toàn bộ array, tensor, làm giảm sự cần thiết phải sử dụng vòng lặp.

b) *Subtraction*

Trong toán học, phép trừ hai số được định nghĩa như sau: Giả sử có hai số a và b , thì $a - b$ là kết quả của phép trừ. Kết quả này cho biết khoảng cách giữa a và b trên trục số.

Đối với phép trừ hai array hoặc tensor cùng kích thước A và B , phép trừ giữa chúng ($A - B$) tạo ra một mảng mới C , với mỗi phần tử C_i được tính bằng cách trừ phần tử B_i khỏi phần tử A_i .

$$C_i = A_i - B_i$$

Tương tự như phép cộng array, tensor, phép trừ cũng là một phép toán element-wise, tức là mỗi phần tử của mảng kết quả được tính bằng cách trừ phần tử tương ứng của mảng thứ nhất cho phần tử tương ứng của mảng thứ hai.

Ví dụ phép trừ hai array trong Numpy, chúng ta có thể sử dụng toán tử "hoặc" hàm `np.subtract()`

```

1 # Numpy code
2 import numpy as np
3 # Tạo hai array 1D
4 arr_1 = np.array([1, 2, 3, 4])
5 arr_2 = np.array([5, 6, 7, 8])
6 print("arr_1:", arr_1)
7 print("arr_2:", arr_2)
8 # Hiệu hai mảng
9 # Cách 1: Sử dụng toán tử '-'
10 result_sub_1 = arr_1 - arr_2
11 # Cách 2: Sử dụng hàm np.subtract()
12 result_sub_2 = np.subtract(arr_1, arr_2)
13 # In ra màn hình
14 print("Cách 1\n", result_sub_1)
15 print("Cách 2\n", result_sub_2)

```

```

===== Output =====
arr_1: [1 2 3 4]
arr_2: [5 6 7 8]
Cách 1
[-4 -4 -4 -4]
Cách 2
[-4 -4 -4 -4]
=====

```

Đối với Pytorch, ta dùng `torch.sub()`.

```

1 # Pytorch code
2 import torch
3 # Tạo hai tensor 1D
4 tensor_1 = torch.tensor([1, 2, 3, 4])
5 tensor_2 = torch.tensor([5, 6, 7, 8])
6 # In ra giá trị của hai tensor

```

```

7 print("tensor 1:", tensor_1)
8 print("tensor 2:", tensor_2)
9 # Hiệu hai tensor
10 # Cách 1: Sử dụng toán tử '-'
11 result_sub_1 = tensor_1 - tensor_2
12 # Cách 2: Sử dụng hàm torch.sub()
13 result_sub_2 = torch.sub(tensor_1, tensor_2)
14 # In ra màn hình
15 print("Cách 1\n", result_sub_1)
16 print("Cách 2\n", result_sub_2)

```

```

===== Output =====
tensor 1: tensor([1, 2, 3, 4])
tensor 2: tensor([5, 6, 7, 8])
Cách 1
  tensor([-4, -4, -4, -4])
Cách 2
  tensor([-4, -4, -4, -4])
=====

```

```

1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo hai tensor 1D
5 tensor_1 = tf.constant([1, 2, 3, 4])
6 tensor_2 = tf.constant([5, 6, 7, 8])
7
8 # In ra giá trị của hai tensor
9 print("tensor 1:", tensor_1)
10 print("tensor 2:", tensor_2)
11
12 # Hiệu hai tensor
13 # Cách 1: Sử dụng toán tử '-'
14 result_sub_1 = tensor_1 - tensor_2
15
16 # Cách 2: Sử dụng hàm tf.subtract()
17 result_sub_2 = tf.subtract(tensor_1, tensor_2)
18
19 # In ra màn hình
20 print("Cách 1\n", result_sub_1)
21 print("Cách 2\n", result_sub_2)

```

```

===== Output =====
tensor 1: tf.Tensor([1 2 3 4], shape=(4,), dtype=int32)
tensor 2: tf.Tensor([5 6 7 8], shape=(4,), dtype=int32)
Cách 1
  tf.Tensor([-4 -4 -4 -4], shape=(4,), dtype=int32)
Cách 2
  tf.Tensor([-4 -4 -4 -4], shape=(4,), dtype=int32)
=====

```


c) *Multiplication*

Phép nhân array **Multiplication**, tensor được thực hiện theo nguyên tắc element-wise: Cho hai array (hoặc tensor) cùng kích thước A và B , phép nhân giữa chúng ($A \cdot B$) tạo ra một array (hoặc tensor) mới C , với mỗi phần tử C_{ij} được tính bằng cách nhân phần tử A_{ij} với phần tử B_{ij} .

$$C_{ij} = A_{ij} \cdot B_{ij}$$

Điều này có thể được diễn đạt theo cách tổng quát như sau:

$$C = A \cdot B$$

Để thực hiện multiplication, ta sử dụng toán tử "*" hoặc hàm multiply.

Ví dụ với thư viện Numpy:

```
1 # Numpy code
2 import numpy as np
3
4 # Tạo hai array 1D
5 arr_1 = np.array([1, 2, 3, 4])
6 arr_2 = np.array([5, 6, 7, 8])
7 # In ra giá trị của hai array
8 print("arr_1:\n", arr_1)
9 print("arr_2:\n", arr_2)
10 # Tích hai array
11 # Cách 1: Sử dụng toán tử '*'
12 result_mul_1 = arr_1 * arr_2
13 # Cách 2: Sử dụng hàm np.multiply()
14 result_mul_2 = np.multiply(arr_1, arr_2)
15 # In ra màn hình
16 print("Cách 1:\n", result_mul_1)
17 print("Cách 2:\n", result_mul_2)
```

```
===== Output =====
arr_1:
 [1 2 3 4]
arr_2:
 [5 6 7 8]
Cách 1:
 [ 5 12 21 32]
Cách 2:
 [ 5 12 21 32]
=====
```

Ví dụ với thư viện Pytorch

```
1 # Pytorch code
2 import torch
3
4 # Tạo hai tensor 1D
5 tensor_1 = torch.tensor([1, 2, 3, 4])
6 tensor_2 = torch.tensor([5, 6, 7, 8])
7
8 # In ra giá trị của hai tensor
9 print("tensor 1:", tensor_1)
10 print("tensor 2:", tensor_2)
11
12 # Tích hai tensor
13 # Cách 1: Sử dụng toán tử '*'
14 result_mul_1 = tensor_1 * tensor_2
15
16 # Cách 2: Sử dụng hàm torch.multiply()
17 result_mul_2 = torch.multiply(tensor_1, tensor_2)
18
19 # In ra màn hình
20 print("Cách 1\n", result_mul_1)
21 print("Cách 2\n", result_mul_2)
```

```
===== Output =====
tensor 1: tensor([1, 2, 3, 4])
tensor 2: tensor([5, 6, 7, 8])
Cách 1
  tensor([ 5, 12, 21, 32])
Cách 2
  tensor([ 5, 12, 21, 32])
=====
```

Ví dụ với thư viện Tensorflow

```
1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo hai tensor 1D
5 tensor_1 = tf.constant([1, 2, 3, 4])
6 tensor_2 = tf.constant([5, 6, 7, 8])
7
8 # In ra giá trị của hai tensor
9 print("tensor 1:\n", tensor_1)
10 print("tensor 2:\n", tensor_2)
11
12 # Tích hai tensor
13 # Cách 1: Sử dụng toán tử '*'
14 result_mul_1 = tensor_1 * tensor_2
15
16 # Cách 2: Sử dụng hàm tf.multiply()
```

```
17 result_mul_2 = tf.multiply(tensor_1, tensor_2)
18
19 # In ra màn hình
20 print("Cách 1:\n", result_mul_1)
21 print("Cách 2:\n", result_mul_2)
```

```
===== Output =====
tensor 1:
tf.Tensor([1 2 3 4], shape=(4,), dtype=int32)
tensor 2:
tf.Tensor([5 6 7 8], shape=(4,), dtype=int32)
Cách 1:
tf.Tensor([ 5 12 21 32], shape=(4,), dtype=int32)
Cách 2:
tf.Tensor([ 5 12 21 32], shape=(4,), dtype=int32)
=====
```

d) *Division*

Phép chia (division) array và tensor được thực hiện theo nguyên tắc element-wise. Cho hai array (hoặc tensor) cùng kích thước A và B , phép chia giữa chúng ($A \div B$) tạo ra một array (hoặc tensor) mới C , với mỗi phần tử C_{ij} được tính bằng cách chia phần tử A_{ij} cho phần tử B_{ij} .

$$C_{ij} = \frac{A_{ij}}{B_{ij}}$$

Để thực hiện phép chia array, tensor, ta có thể sử dụng toán tử $/$ hoặc hàm `divide()`.

Ví dụ với thư viện Numpy:

```
1 # Numpy code
2 import numpy as np
3
4 # Tạo hai array 1D
5 arr_1 = np.array([1, 2, 3, 4])
6 arr_2 = np.array([5, 6, 7, 8])
7 # In ra giá trị của hai array
8 print("arr_1:\n", arr_1)
9 print("arr_2:\n", arr_2)
10 # Chia hai array
11 # Cách 1: Sử dụng toán tử '/'
12 result_div_1 = arr_1 / arr_2
13 # Cách 2: Sử dụng hàm np.divide()
14 result_div_2 = np.divide(arr_1, arr_2)
15 # In ra màn hình
16 print("Cách 1:\n", result_div_1)
17 print("Cách 2:\n", result_div_2)
```

```
===== Output =====
arr_1:
 [1 2 3 4]
arr_2:
 [5 6 7 8]
Cách 1:
 [0.2      0.33333333 0.42857143 0.5]
Cách 2:
 [0.2      0.33333333 0.42857143 0.5]
=====
```

Ví dụ với thư viện Pytorch:

```
1 # Pytorch code
2 import torch
3
4 # Tạo hai tensor 1D
5 tensor_1 = torch.tensor([1, 2, 3, 4])
6 tensor_2 = torch.tensor([5, 6, 7, 8])
7 # In ra giá trị của hai tensor
```

```
8 print("tensor 1:\n", tensor_1)
9 print("tensor 2:\n", tensor_2)
10 # Chia hai tensor
11 # Cách 1: Sử dụng toán tử '/'
12 result_div_1 = tensor_1 / tensor_2
13 # Cách 2: Sử dụng hàm torch.div()
14 result_div_2 = torch.divide(tensor_1, tensor_2)
15 # In ra màn hình
16 print("Cách 1:\n", result_div_1)
17 print("Cách 2:\n", result_div_2)
```

```
===== Output =====
tensor 1:
  tensor([1, 2, 3, 4])
tensor 2:
  tensor([5, 6, 7, 8])
Cách 1:
  tensor([0.2000, 0.3333, 0.4286, 0.5000])
Cách 2:
  tensor([0.2000, 0.3333, 0.4286, 0.5000])
=====
```

Ví dụ với thư viện Tensorflow:

```

1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo hai tensor 1D
5 tensor_1 = tf.constant([1, 2, 3, 4])
6 tensor_2 = tf.constant([5, 6, 7, 8])
7 # In ra giá trị của hai tensor
8 print("tensor 1:\n", tensor_1)
9 print("tensor 2:\n", tensor_2)
10 # Chia hai tensor
11 # Cách 1: Sử dụng toán tử '/'
12 result_div_1 = tensor_1 / tensor_2
13 # Cách 2: Sử dụng hàm tf.divide()
14 result_div_2 = tf.divide(tensor_1, tensor_2)
15 # In ra màn hình
16 print("Cách 1:\n", result_div_1)
17 print("Cách 2:\n", result_div_2)

```

```

===== Output =====
tensor 1:
tf.Tensor([1 2 3 4], shape=(4,), dtype=int32)
tensor 2:
tf.Tensor([5 6 7 8], shape=(4,), dtype=int32)
Cách 1:
tf.Tensor([0.2          0.33333333 0.42857143 0.5          ], shape=(4,), dtype=float64)
Cách 2:
tf.Tensor([0.2          0.33333333 0.42857143 0.5          ], shape=(4,), dtype=float64)
=====

```

e) *Inner product*

Phép tính tích vô hướng (inner product), còn được biết đến với tên gọi khác là dot product. Phép tích vô hướng giữa hai vector có thể được tính để đo lường sự tương quan hoặc hướng của chúng.

- Cho hai vectơ $\mathbf{a} = [a_1, a_2, \dots, a_n]$ và $\mathbf{b} = [b_1, b_2, \dots, b_n]$ trong không gian Euclidean $\mathbb{R}^n$, phép tích vô hướng của chúng được xác định bởi công thức:

$$\mathbf{a} \cdot \mathbf{b} = a_1 b_1 + a_2 b_2 + \dots + a_n b_n$$

- Công thức này còn được biểu diễn dưới dạng sigma:

$$\mathbf{a} \cdot \mathbf{b} = \sum_{i=1}^n a_i b_i$$

Trong thư viện Numpy, hàm `np.dot()` được sử dụng để thực hiện phép nhân ma trận, và nó cũng hỗ trợ tích vô hướng cho các vectơ. Cú pháp:

```
1 Numpy.dot(a, b, out=None)
```

Trong đó: a, b: Các mảng hoặc vectơ để thực hiện phép nhân. Các chiều của a và b phải thích hợp để thực hiện phép nhân (ví dụ, số cột của a phải bằng số hàng của b). out: Mảng để lưu trữ kết quả. Nếu không được chỉ định, một mảng mới sẽ được tạo.

```
1 # Numpy code
2 import numpy as np
3
4 # Tạo hai array 1D
5 arr_1 = np.array([1, 2])
6 arr_2 = np.array([2, 3])
7 # In ra giá trị của hai array
8 print("arr_1:\n", arr_1)
9 print("arr_2:\n", arr_2)
10 # Sử dụng hàm np.dot()
11 result_dot = np.dot(arr_1, arr_2)
12 # In ra màn hình
13 print("Kết quả tích vô hướng arr_1, arr_2:\n", result_dot)
```

```
===== Output =====
arr_1:
 [1 2]
arr_2:
 [2 3]
Kết quả tích vô hướng arr_1, arr_2:
 8
=====
```

Trong Pytorch, hàm **torch.dot()** được sử dụng để thực hiện tích vô hướng (dot product) giữa hai vectơ. Tuy nhiên khác với Numpy có thể tính tích của các array nhiều chiều thì hàm này chỉ cho phép tính tích vô hướng của hai vector 1D. Cú pháp:

```
1 torch.dot(tensor1, tensor2)
```

Trong đó, tensor1, tensor2: Hai tensor có cùng kích thước để thực hiện tích vô hướng. Kết quả trả về sẽ là một số vô hướng.

Trong Tensorflow, hàm **tf.tensordot()** được sử dụng để thực hiện phép nhân tensor với nhau theo các chiều chỉ định. Nó có thể được sử dụng để thực hiện nhiều loại phép nhân tensor, bao gồm cả phép nhân ma trận và tích vô hướng. Cú pháp:

```
1 tf.tensordot(a, b, axes)
```

Trong đó, các tham số được định nghĩa như sau:

- a, b: Hai tensor để thực hiện phép nhân.

- axes: Một tuple hoặc số nguyên chỉ định các chiều của a và b được sử dụng trong phép nhân. Nếu là một số nguyên, nó xác định số chiều được sử dụng trong cả a và b.

Tóm lại thì khi thực hiện tích vô hướng hai vector thì chúng ta dùng dot product. Với thư viện Numpy và Tensorflow thì chúng ta có thể áp dụng dot product với array, tensor nhiều chiều phức tạp hơn.

f) *Matrix-matrix multiplication*

Trong toán học, phép nhân ma trận (matrix multiplication) thường được biểu diễn bằng dấu chấm ($\cdot$) hoặc dấu nhân ($\times$). Các ma trận A và B có thể được nhân với nhau để tạo ra một ma trận kết quả C , với điều kiện số cột của ma trận A bằng số hàng của ma trận B .

Giả sử A là một ma trận có kích thước $m \times n$ (m hàng, n cột), và B là một ma trận có kích thước $n \times p$ (n hàng, p cột), thì ma trận kết quả C sẽ có kích thước $m \times p$. Quy tắc này còn được biết đến như là quy tắc hàng-cột, vì mỗi phần tử của ma trận kết quả C được tính bằng cách lấy tổng của tích từng phần tử của hàng tương ứng của ma trận A và cột tương ứng của ma trận B .

Phép nhân ma trận $C = A \times B$ có thể được mô tả như sau:

$$C_{ij} = \sum_{k=1}^n A_{ik} \cdot B_{kj}$$

Trong đó: - C_{ij} là phần tử ở hàng thứ i và cột thứ j của ma trận C . - A_{ik} là phần tử ở hàng thứ i và cột thứ k của ma trận A . - B_{kj} là phần tử ở hàng thứ k và cột thứ j của ma trận B . - Phép toán $\sum_{k=1}^n$ biểu thị việc tính tổng qua tất cả các giá trị của k từ 1 đến n .

Ví dụ:

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \times \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{bmatrix}$$

Trong trường hợp này, $C_{11} = A_{11} \cdot B_{11} + A_{12} \cdot B_{21}$, $C_{12} = A_{11} \cdot B_{12} + A_{12} \cdot B_{22}$, và tương tự cho các phần tử còn lại của ma trận C .

Trong thư viện Numpy, hàm **np.matmul()** được sử dụng để thực hiện phép nhân ma trận. Hàm này cung cấp một cách linh hoạt để thực hiện nhân ma trận giữa các mảng (hoặc tensor) Numpy. Sử dụng cú pháp:

```
1 np.matmul(a, b, out=None)
```

Trong đó các tham số được định nghĩa như sau:

- a, b: Các ma trận (hoặc mảng) để thực hiện phép nhân. Số cột của ma trận a phải bằng số hàng của ma trận b.
- out: Mảng kết quả. Nếu được chỉ định, kết quả sẽ được lưu trữ vào mảng này.


```

1 # Numpy code
2 import numpy as np
3
4 # Tạo 2 array 2D
5 arr_1 = np.array([[1, 2], [3, 4]])
6 arr_2 = np.array([[5, 6], [7, 8]])
7
8 # In ra giá trị của hai array
9 print("arr_1:\n", arr_1)
10 print("arr_2:\n", arr_2)
11
12 # Sử dụng hàm np.matmul()
13 result_matmul = np.matmul(arr_1, arr_2)
14
15 # In ra màn hình
16 print("Kết quả tích arr_1, arr_2:\n", result_matmul)

```

```

===== Output =====
arr_1:
[[1 2]
 [3 4]]
arr_2:
[[5 6]
 [7 8]]
Kết quả tích arr_1, arr_2:
[[19 22]
 [43 50]]
=====

```

Trong Pytorch, hàm **torch.matmul()** được sử dụng để thực hiện phép nhân ma trận (matrix multiplication) giữa hai tensor. Hàm này hỗ trợ cả tính tích vô hướng cho vectơ và cũng có thể được sử dụng cho các trường hợp phức tạp hơn. Cú pháp sử dụng là:

```

1 torch.matmul(input, other, out=None)

```

Hàm này sẽ trả về kết quả của phép nhân ma trận, trong đó các tham số được định nghĩa như sau:

- input: Tensor đầu tiên để thực hiện phép nhân ma trận.
- other: Tensor thứ hai để thực hiện phép nhân ma trận.
- out: Tensor để lưu trữ kết quả. Nếu không được chỉ định, một tensor mới sẽ được tạo.

Ví dụ:

```

1 # Pytorch code
2 import torch
3
4 # Tạo hai tensor 2D

```

```

5 tensor_1 = torch.tensor([[1, 2], [3, 4]])
6 tensor_2 = torch.tensor([[5, 6], [7, 8]])
7
8 # In ra giá trị của hai tensor
9 print("tensor 1:\n", tensor_1)
10 print("tensor 2:\n", tensor_2)
11
12 # Sử dụng hàm torch.matmul()
13 result_matmul = torch.matmul(tensor_1, tensor_2)
14
15 # In ra màn hình
16 print("Kết quả tích tensor_1, tensor_2:\n", result_matmul)

```

```

===== Output =====
tensor 1:
  tensor([[1, 2],
          [3, 4]])
tensor 2:
  tensor([[5, 6],
          [7, 8]])
Kết quả tích tensor_1, tensor_2:
  tensor([[19, 22],
          [43, 50]])
=====

```

Hàm **tf.matmul()** trong Tensorflow được sử dụng để thực hiện phép nhân ma trận giữa hai tensor. Nó hỗ trợ cả việc thực hiện phép nhân ma trận và tích vô hướng cho các tensor có số chiều khác nhau. Cú pháp:

```

1 tf.matmul(a, b, transpose_a=False, transpose_b=False, adjoint_a=False, adjoint_b=False,
  a_is_sparse=False, b_is_sparse=False, name=None)

```

Hàm này trả về kết quả là phép nhân ma trận, trong đó các tham số được định nghĩa như sau:

- a, b: Hai tensor để thực hiện phép nhân ma trận.
- transpose_a, transpose_b: Xác định xem có nên chuyển vị các tensor a và b trước khi thực hiện phép nhân hay không.
- adjoint_a, adjoint_b: Xác định xem có nên sử dụng chuyển vị liên ngược của các tensor a và b trước khi thực hiện phép nhân hay không.
- a_is_sparse, b_is_sparse: Xác định xem tensor a và b có là tensor thưa (sparse) hay không.
- name: Tên của phép toán, thường để mặc định là None

Ví dụ:

```

1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo hai tensor 2D
5 tensor_1 = tf.constant([[1, 2], [3, 4]])
6 tensor_2 = tf.constant([[5, 6], [7, 8]])
7
8 # In ra giá trị của hai tensor
9 print("tensor 1:\n", tensor_1)
10 print("tensor 2:\n", tensor_2)
11
12 # Tích hai tensor
13 result_matmul = tf.matmul(tensor_1, tensor_2)
14
15 # In ra màn hình
16 print("Kết quả tích:\n", result_matmul)

```

```

===== Output =====
tensor 1:
tf.Tensor(
[[1 2]
 [3 4]], shape=(2, 2), dtype=int32)
tensor 2:
tf.Tensor(
[[5 6]
 [7 8]], shape=(2, 2), dtype=int32)
Kết quả tích:
tf.Tensor(
[[19 22]
 [43 50]], shape=(2, 2), dtype=int32)
=====

```

Mặc dù hàm `matmul` khá giống với dot product ở phần trước, nhưng hai hàm này là khác nhau nên ta cần chú ý khi sử dụng chúng.

g) Chuyển vị - *Transpose*

Chuyển vị (Transpose) là một phép toán quan trọng trong đại số tuyến tính, nó thực hiện thay đổi vị trí của các hàng thành cột và ngược lại trong một ma trận. Ký hiệu của phép toán chuyển vị thường được biểu diễn bằng ký hiệu T hoặc là $\top$. Nếu A là một ma trận, thì chuyển vị của A được ký hiệu là A^T hoặc $A^\top$.

Công Thức Chuyển Vị:

Nếu A là một ma trận với các phần tử a_{ij} , thì chuyển vị của A , ký hiệu là A^T hay $A^\top$, có kích thước là số cột của A trở thành số hàng của A và ngược lại. Cụ thể, nếu A có kích thước $m \times n$, thì A^T có kích thước $n \times m$.

$$(A^T)_{ij} = A_{ji}$$

Ví dụ:

Giả sử có ma trận A như sau:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

Chuyển vị của A , ký hiệu là A^T , sẽ là:

$$A^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}$$

Một số tính chất của phép chuyển vị:

- Chuyển vị của một ma trận chuyển vị lại sẽ cho ra ma trận ban đầu: $(A^T)^T = A$.
- Chuyển vị của tổng hai ma trận bằng tổng chuyển vị của từng ma trận: $(A+B)^T = A^T + B^T$.
- Chuyển vị của tích hai ma trận bằng tích đảo ngược vị trí của chuyển vị từng ma trận: $(AB)^T = B^T A^T$.

Ví dụ:

```

1 # Numpy code
2 import numpy as np
3
4 #Tạo array 2d
5 arr_1 = np.array([[1, 2], [3, 4]])
6 # Chuyển vị array
7 # Cách 1: Sử dụng hàm np.transpose()
8 arr_transposed_1 = np.transpose(arr_1)
9 # Cách 2: Sử dụng toán tử T
10 arr_transposed_2 = arr_1.T
11 # In ra màn hình
12 print("array 1:\n", arr_1)
13 print("array 1 sau khi chuyển vị, cách 1:\n", arr_transposed_1)
14 print("array 1 sau khi chuyển vị, cách 2:\n", arr_transposed_2)

```

```

===== Output =====
array 1:
[[1 2]
 [3 4]]
array 1 sau khi chuyển vị, cách 1:
[[1 3]
 [2 4]]
array 1 sau khi chuyển vị, cách 2:
[[1 3]
 [2 4]]
=====

```

Trong Numpy, chuyển vị của một mảng (array) có thể được thực hiện bằng cách sử dụng hàm **np.transpose()** hoặc toán tử chuyển vị **.T**. Chuyển vị thay đổi vị trí của các hàng thành cột và ngược lại trong array.

Trong Pytorch, chuyển vị của tensor có thể được thực hiện bằng cách sử dụng hàm **torch.t()** hoặc **torch.transpose()**. Chuyển vị thay đổi vị trí của các hàng thành cột và ngược lại trong tensor. Cú pháp:

```
1 #cách 1:
2 torch.t(input)
3
4 #Cách 2
5 torch.transpose(input, dim0, dim1)
```

Kết quả trả về là một tensor mới là kết quả của phép chuyển vị. Trong đó:

- input: Tensor cần được chuyển vị.
- dim0, dim1: Các chiều được chọn để thực hiện chuyển vị.

Ví dụ:

```
1
2 #Pytorch code
3 import torch
4
5 #Tạo tensor 2d
6 tensor_1 = torch.tensor([[1, 2], [3, 4]])
7 # Chuyển vị tensor
8 # Cách 1: Sử dụng hàm torch.t()
9 tensor_transposed_1 = torch.t(tensor_1)
10 # Cách 2: Sử dụng hàm torch.transpose()
11 tensor_transposed_2 = torch.transpose(tensor_1, 0, 1)
12
13 # In ra màn hình
14 print("tensor 1:\n", tensor_1)
15 print("tensor 1 sau khi chuyển vị, cách 1:\n", tensor_transposed_1)
16 print("tensor 1 sau khi chuyển vị, cách 2:\n", tensor_transposed_2)
```

```
===== Output =====
tensor 1:
  tensor([[1, 2],
          [3, 4]])
tensor 1 sau khi chuyển vị, cách 1:
  tensor([[1, 3],
          [2, 4]])
tensor 1 sau khi chuyển vị, cách 2:
  tensor([[1, 3],
          [2, 4]])
=====
```

Trong Tensorflow, không có toán tử chuyển vị **T**, mà chỉ dùng hàm **tf.transpose()**. Cách sử dụng cũng tương tự như Numpy và Pytorch:

Ví dụ:

```
1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo tensor 2d
5 tensor_1 = tf.constant([[1, 2], [3, 4]])
6 # Chuyển vị tensor
7 tensor_transposed = tf.transpose(tensor_1)
8
9 # In ra màn hình
10 print("tensor 1:\n", tensor_1)
11 print("tensor 1 sau khi chuyển vị:\n", tensor_transposed)
```

```
===== Output =====
tensor 1:
tf.Tensor(
[[1 2]
 [3 4]], shape=(2, 2), dtype=int32)
tensor 1 sau khi chuyển vị:
tf.Tensor(
[[1 3]
 [2 4]], shape=(2, 2), dtype=int32)
=====
```

h) *Summation*

Trong thư viện Numpy, hàm **np.sum()** được sử dụng để tính tổng của các phần tử trong mảng (array). Hàm này có thể được áp dụng trên các mảng 1D, 2D hoặc có số chiều cao hơn. Cú pháp:

```
1 np.sum(a, axis=None, dtype=None, keepdims=False, initial=0, where=True)
```

Trong đó:

- a: Mảng đầu vào.
- axis: (Tùy chọn) Chiều hoặc các chiều trên đó tổng sẽ được thực hiện. Mặc định là None, tức là tổng của tất cả các phần tử trong mảng.
- dtype: (Tùy chọn) Kiểu dữ liệu của kết quả.
- keepdims: (Tùy chọn) Nếu là True, giữ chiều của mảng kết quả (nếu có) giống với chiều của mảng đầu vào.
- initial: (Tùy chọn) Giá trị khởi tạo cho tổng.

- where: (Tùy chọn) Một mảng Boolean chỉ định vị trí các phần tử được sử dụng trong phép toán.

Ví dụ:

```

1 # Numpy code
2 import numpy as np
3
4 # Tạo mảng 2D
5 arr = np.array([[1, 2, 3],
6                 [4, 5, 6]])
7
8 # Tính tổng của tất cả các phần tử trong mảng
9 total_sum = np.sum(arr)
10
11 # Tính tổng theo cột (theo chiều dọc)
12 column_sum = np.sum(arr, axis=0)
13
14 # Tính tổng theo hàng (theo chiều ngang)
15 row_sum = np.sum(arr, axis=1)
16
17 # In ra màn hình
18 print("Mảng:\n", arr)
19 print("Tổng của tất cả các phần tử trong mảng:\n", total_sum)
20 print("Tổng theo cột:\n", column_sum)
21 print("Tổng theo hàng:\n", row_sum)

```

```

===== Output =====
Mảng:
[[1 2 3]
 [4 5 6]]
Tổng của tất cả các phần tử trong mảng:
21
Tổng theo cột:
[5 7 9]
Tổng theo hàng:
[ 6 15]
=====

```

Trong ví dụ trên, **np.sum()** được sử dụng để tính tổng của mảng array. Tham số sử dụng ở đây là mặc định khi tính tổng các phần tử trong toàn bộ array, sử dụng tham số axis để tính tổng theo cột hoặc hàng. Kết quả được in ra màn hình bao gồm tổng của tất cả các phần tử, tổng theo cột, và tổng theo hàng của mảng.

Trong Pytorch, chúng ta tính sum tương tự như trong Numpy, ví dụ:

```

1 #Pytorch code
2 import torch
3
4 # Tạo tensor 2d
5 tensor_1 = torch.tensor([[1, 2], [3, 4]])

```

```

6 # Tính tổng tensor
7 tensor_sum = torch.sum(tensor_1)
8 # Tính tổng tensor theo cột axis = 0
9 tensor_sum_axis_0 = torch.sum(tensor_1, axis=0)
10 # Tính tổng tensor theo hàng axis = 1
11 tensor_sum_axis_1 = torch.sum(tensor_1, axis=1)
12
13 # In ra màn hình
14 print("tensor:\n", tensor_1)
15 print("Tổng các phần tử trong tensor:\n", tensor_sum)
16 print("Tổng theo cột:\n", tensor_sum_axis_0)
17 print("Tổng theo hàng:\n", tensor_sum_axis_1)

```

```

===== Output =====
tensor:
  tensor([[1, 2],
          [3, 4]])
Tổng các phần tử trong tensor:
  tensor(10)
Tổng theo cột:
  tensor([4, 6])
Tổng theo hàng:
  tensor([3, 7])
=====

```

Ví dụ tính sum trong Tensorflow:

```

1 # Tensorflow code
2 import tensorflow as tf
3
4 # Tạo tensor 2d
5 tensor_1 = tf.constant([[1, 2], [3, 4]])
6 # Tính tổng tensor
7 tensor_sum = tf.reduce_sum(tensor_1)
8 # Tính tổng tensor theo cột axis = 0
9 tensor_sum_axis_0 = tf.reduce_sum(tensor_1, axis=0)
10 # Tính tổng tensor theo hàng axis = 1
11 tensor_sum_axis_1 = tf.reduce_sum(tensor_1, axis=1)
12
13 # In ra màn hình
14 print("tensor:\n", tensor_1)
15 print("Tổng các phần tử trong tensor:\n", tensor_sum)
16 print("Tổng theo cột:\n", tensor_sum_axis_0)
17 print("Tổng theo hàng:\n", tensor_sum_axis_1)

```

```

===== Output =====
tensor:
  tf.Tensor(
[[1 2]
 [3 4]], shape=(2, 2), dtype=int32)

```



```
Tổng các phần tử trong tensor:
tf.Tensor(10, shape=(), dtype=int32)
Tổng theo cột:
tf.Tensor([4 6], shape=(2,), dtype=int32)
Tổng theo hàng:
tf.Tensor([3 7], shape=(2,), dtype=int32)
=====
```

i) *Broadcasting*

Broadcasting giúp thực hiện các phép toán trên các mảng có hình dạng (shape) khác nhau mà không cần phải tạo ra các bản sao của mảng. Điều này làm giảm đáng kể lượng bộ nhớ được sử dụng và cải thiện hiệu suất tính toán.

Numpy thực hiện broadcasting theo các quy tắc sau:

- Nếu mảng không có cùng số chiều, thêm các chiều với kích thước 1 ở phía trước của mảng có ít chiều.
- Nếu mảng có số chiều khác nhau, mở rộng chiều của mảng có ít chiều để chúng có cùng số chiều.

```
1 # Numpy code
2 import numpy as np
3
4 # Tạo mảng 2D
5 arr_1 = np.array([[1, 2, 3]])
6 arr_2 = np.array([[4], [5], [6]])
7
8 # Thực hiện cộng hai mảng, broadcasting sẽ được thực hiện
9 result = arr_1 + arr_2
10
11 print("arr_1:\n", arr_1)
12 print("arr_2:\n", arr_2)
13 print("result:\n", result)
```

```
===== Output =====
arr_1:
[[1 2 3]]
arr_2:
[[4]
 [5]
 [6]]
result:
[[5 6 7]
 [6 7 8]
 [7 8 9]]
=====
```

Trong ví dụ trên, NumPy tự động mở rộng **arr_1** thành một ma trận 3x3 và **arr_2** thành một ma trận 3x3 để thực hiện phép cộng. Cơ chế broadcasting trong PyTorch và TensorFlow tương tự như NumPy, theo các quy tắc giống nhau.

Qua các ví dụ trên, điều mà ta nên nhận thấy là các thư viện có thể có các cú pháp khác nhau, tuy nhiên thì chúng đều có điểm chung là bản chất toán học giống nhau. Tức là thư viện ở đây có thể hiểu là công cụ để chúng ta thực hiện các phép tính toán. (Lưu ý: Nhận xét này chỉ giới hạn những phần toán học cơ bản được trình bày trong bài viết, không bao quát cho toàn bộ khía cạnh của thư viện, vì mỗi thư viện sẽ có những phần rất riêng có thể sẽ được phân tích trong các bài viết khác.)

IV. Conclusion

Trong bài viết này, chúng ta đã tìm hiểu và so sánh cách sử dụng các thư viện lập trình học máy phổ biến - **Numpy, Pytorch, và Tensorflow** - thông qua việc thực hiện các phép toán cơ bản trên mảng và tens như cộng, trừ, nhân, chia, đến các phép toán phức tạp hơn như tích vô hướng, nhân ma trận, chuyển vị, và tính tổng..., chúng ta đã thấy rằng mặc dù mỗi thư viện có cú pháp riêng, nhưng cùng xây dựng trên nền tảng toán học giống nhau và có thể chuyển đổi kiểu dữ liệu của các thư viện này với nhau. Chúng ta cũng thấy rằng Broadcasting, một tính năng quan trọng trong các thư viện này có khả năng xử lý hiệu quả các mảng có kích thước khác nhau trong các phép toán. Điều này giúp cải thiện hiệu suất tính toán và giảm bộ nhớ sử dụng, một yếu tố quan trọng trong xử lý dữ liệu lớn và học máy. Những ví dụ và minh họa cung cấp trong tài liệu không chỉ giúp hiểu rõ hơn về cách sử dụng các thư viện này mà còn góp phần vào việc xây dựng nền tảng vững chắc cho việc ứng dụng chúng trong nghiên cứu khoa học dữ liệu và phát triển trí tuệ nhân tạo. Sự hiểu biết này sẽ là hành trang quý báu cho những ai muốn tiến xa hơn trong lĩnh vực khoa học dữ liệu và học máy.