

## CHUYÊN ĐỀ 1

# HỌC MÁY CỔ ĐIỂN

## BÀI 1 — NỀN TẢNG HỌC MÁY

*Từ dữ liệu → mô hình → dự đoán → mất mát → huấn luyện → suy luận*

### MỤC TIÊU

Tài liệu được biên soạn cho học sinh trung học phổ thông đã biết lập trình cơ bản và đang chuyển từ C++ sang Python, với mục tiêu tiến tới các kỳ thi Olympic Trí tuệ nhân tạo trong nước và quốc tế. Nội dung ưu tiên hiểu bản chất, kiểm tra kích thước dữ liệu, tự tính ví dụ, rồi mới sử dụng thư viện.

Nguồn và phạm vi được kiểm tra ngày 22 tháng 9 năm 2026

## KIỂM TRA PHẠM VI

Tên chủ đề: Học máy cổ điển (Classical Machine Learning).

Nguồn chính để xác định phạm vi: International Olympiad in Artificial Intelligence 2026 Syllabus, do International Scientific Committee công bố trên trang chính thức. Tại thời điểm biên soạn, trang chính thức đã công bố kỳ thi năm 2027 tại Singapore nhưng chưa công bố một syllabus năm 2027 mới thay thế bản 2026. Vì vậy tài liệu này dùng syllabus 2026 làm mốc chính thức mới nhất có thể kiểm chứng trực tiếp.

[CHÍNH THỨC TRONG SYLLABUS]

| Nhóm                   | Nội dung                                                                                                                                                                                 | Mức yêu cầu               |
|------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------|
| Lập trình nền tảng     | Python; NumPy và Pandas; scikit-learn; thao tác tensor                                                                                                                                   | Thực hành                 |
| Học máy có giám sát    | Hồi quy tuyến tính; hồi quy logistic; điều chuẩn chuẩn một và chuẩn hai; K láng giềng gần nhất; cây quyết định; máy vectơ hỗ trợ                                                         | Cả lý thuyết và thực hành |
| Mô hình tổ hợp         | Gradient Boosting; Bagging; Random Forest                                                                                                                                                | Thực hành                 |
| Học máy không giám sát | K-Means; phân tích thành phần chính                                                                                                                                                      | Cả lý thuyết và thực hành |
| Học máy không giám sát | t-Distributed Stochastic Neighbor Embedding; Uniform Manifold Approximation and Projection; Density-Based Spatial Clustering of Applications with Noise; phân cụm phân cấp; phân cụm phổ | Thực hành                 |
| Khoa học dữ liệu       | Accuracy; Precision; Recall; F1 Score; ma trận nhầm lẫn; đường cong Receiver Operating Characteristic                                                                                    | Cả lý thuyết và thực hành |
| Khoa học dữ liệu       | Underfitting; Overfitting                                                                                                                                                                | Lý thuyết                 |
| Khoa học dữ liệu       | Điều chỉnh siêu tham số; Cross-Validation; Feature Engineering; Data Processing                                                                                                          | Thực hành                 |

GHI CHÚ QUỐC TẾ THỨ HAI

International Artificial Intelligence Olympiad 2026 cũng công bố chính thức các chủ đề Học máy có giám sát, Học máy không giám sát và đánh giá mô hình; trang này xác nhận toán học và lập trình đều là phần thiết yếu và toàn bộ lập trình, mô hình hóa được thực hiện bằng Python. Tài liệu hiện tại không trộn lẫn hai syllabus: syllabus của International Olympiad in Artificial Intelligence được dùng làm mốc phân loại chính; syllabus của International Artificial Intelligence Olympiad chỉ được dùng để đối chiếu thêm.

**PHẠM VI VIỆT NAM**

Trang chính thức của Olympic Trí tuệ nhân tạo Việt Nam xác nhận kỳ tuyển chọn năm 2026 hướng tới chọn 8 học sinh dự International Artificial Intelligence Olympiad 2027 tại Đà Nẵng. Tuy nhiên, trong lần kiểm tra này chưa tìm thấy syllabus Việt Nam công khai đủ chi tiết để gắn nhãn từng thuật toán là yêu cầu chính thức. Vì vậy giáo trình không tự suy đoán phạm vi thi Việt Nam.

**ĐỀ XUẤT CHIA CHỦ ĐỀ HỌC MÁY CỔ ĐIỂN**

1. Nền tảng Học máy: dữ liệu, đặc trưng, nhãn, mô hình, huấn luyện và suy luận
2. Hồi quy tuyến tính
3. Hồi quy đa thức
4. Hồi quy logistic
5. Điều chuẩn chuẩn một và chuẩn hai
6. Phương pháp K láng giềng gần nhất
7. Cây quyết định
8. Bagging, Random Forest và Gradient Boosting
9. Máy vectơ hỗ trợ
10. Naive Bayes
11. Phân cụm K-Means
12. Phân cụm phân cấp, Gaussian Mixture Model, Density-Based Spatial Clustering of Applications with Noise và phân cụm phổ
13. Phân tích thành phần chính
14. t-Distributed Stochastic Neighbor Embedding và Uniform Manifold Approximation and Projection
15. Các thước đo đánh giá mô hình
16. Underfitting, Overfitting và Bias-Variance
17. Cross-Validation và lựa chọn siêu tham số
18. Feature Engineering, tiền xử lý dữ liệu và Data Leakage

## MỤC LỤC BÀI 1

1. Chủ đề này nằm ở đâu trong bức tranh Trí tuệ nhân tạo?
2. Mục tiêu bài học
3. Kiến thức tiên quyết
4. Từ vựng và khái niệm
5. Vấn đề mà thuật toán giải quyết
6. Trực giác
7. Mô hình toán học
8. Giải thích từng công thức
9. Suy ra công thức
10. Ví dụ tính bằng tay
11. Thuật toán
12. Pseudocode
13. Độ phức tạp
14. Cài đặt từ đầu
15. Cài đặt bằng thư viện
16. Theo dõi dữ liệu qua toàn bộ thuật toán
17. Huấn luyện và suy luận
18. Các siêu tham số
19. Giả định của phương pháp
20. Ưu điểm và hạn chế
21. So sánh với phương pháp liên quan
22. Những lỗi học sinh rất dễ mắc
23. Góc nhìn Olympic
24. Bài tập luyện tập
25. Lời giải
26. Kiểm tra mức độ hiểu
27. Tóm tắt cuối bài
28. Bản đồ liên kết kiến thức
29. Tài liệu tham khảo

# PHẦN 1 — CHỦ ĐỀ NÀY NẴM Ở ĐÂU TRONG BỨC TRANH TRÍ TUỆ NHÂN TẠO?

## [NỀN TẢNG CẦN THIẾT]

Trí tuệ nhân tạo là một lĩnh vực rộng. Học máy (Machine Learning) là một nhánh trong đó máy tính sử dụng dữ liệu để xây dựng một mô hình có khả năng thực hiện một nhiệm vụ, thay vì con người phải viết toàn bộ quy tắc xử lý cho từng trường hợp.

### TRỰC GIÁC — KHÔNG PHẢI ĐỊNH NGHĨA TOÁN HỌC

Trong lập trình truyền thống, ta thường cung cấp dữ liệu và quy tắc để nhận kết quả. Trong Học máy có giám sát, ta cung cấp nhiều ví dụ gồm đầu vào và đáp án đúng; thuật toán dùng các ví dụ đó để tìm một mô hình, rồi mô hình được dùng để dự đoán cho dữ liệu mới.

```

Lập trình thông thường
Dữ liệu + Quy tắc do con người viết
    ↓
Chương trình
    ↓
Kết quả

Học máy có giám sát
Dữ liệu + Đáp án đúng
    ↓
Thuật toán học
    ↓
Mô hình đã học
    ↓
Dữ liệu mới → Dự đoán
  
```

Bản đồ kiến thức của giai đoạn đầu:

```

Python
↓
NumPy và Pandas
↓
Vector và ma trận
↓
Dữ liệu, đặc trưng và nhãn
↓
Học máy có giám sát
↓
Hồi quy tuyến tính
↓
Hồi quy logistic
↓
Cây quyết định / Máy vector hỗ trợ
↓
Mô hình tổ hợp
  
```

## PHẦN 2 — MỤC TIÊU BÀI HỌC

- Giải thích bằng lời Học máy là gì và vì sao cần nó.
- Phân biệt Học máy có giám sát và Học máy không giám sát.
- Nhận biết mẫu dữ liệu, đặc trưng, nhãn và biến mục tiêu.
- Phân biệt bài toán hồi quy với bài toán phân loại.
- Biểu diễn dữ liệu bằng ma trận  $X$  và vector  $y$ ; đọc đúng shape.
- Phân biệt tham số của mô hình với siêu tham số.
- Hiểu vai trò của hàm mất mát trong quá trình học.
- Phân biệt huấn luyện và suy luận.
- Hiểu tập huấn luyện, tập kiểm định và tập kiểm tra.
- Nhận biết các dạng rò rỉ dữ liệu cơ bản.
- Sử dụng NumPy và Pandas để biểu diễn dữ liệu nhỏ.
- Sử dụng `train_test_split` đúng mục đích và hiểu điều nó không tự làm.

## PHẦN 3 — KIẾN THỨC TIỀN QUYẾT

### A. Toán học

Cần biết đến mức: số thực, biến, hàm số, tổng, trung bình cộng, lũy thừa bậc hai, tọa độ và vector cơ bản. Chưa cần biết trước đạo hàm riêng, gradient hay đại số tuyến tính nâng cao; những kiến thức đó sẽ được dạy khi cần.

### B. Lập trình

Cần biết biến, câu lệnh điều kiện, vòng lặp, hàm, danh sách Python và thao tác nhập/xuất cơ bản. Nếu đang chuyển từ C++ sang Python, mục tiêu quan trọng nhất ở bài này là làm quen tư duy dữ liệu theo mảng và bảng.

### C. Học máy

Không yêu cầu kiến thức trước. Đây là bài nền tảng để xây dựng từ vựng và khung tư duy ban đầu.

## PHẦN 4 — TỪ VỰNG VÀ KHÁI NIỆM

| Thuật ngữ tiếng Việt | Thuật ngữ tiếng Anh | Ký hiệu   | Ý nghĩa chính xác                                     |
|----------------------|---------------------|-----------|-------------------------------------------------------|
| Mẫu dữ liệu          | Sample              | $x^{(i)}$ | Một quan sát hoặc đối tượng cụ thể trong tập dữ liệu. |
| Đặc trưng            | Feature             | $x_j$     | Một thuộc tính đầu vào dùng để mô tả mẫu.             |
| Nhãn                 | Label               | $y$       | Đáp án đúng trong bài toán phân loại có giám sát.     |
| Biến mục tiêu        | Target              | $y$       | Giá trị mà mô hình cần dự đoán.                       |

| Thuật ngữ tiếng Việt | Thuật ngữ tiếng Anh | Ký hiệu   | Ý nghĩa chính xác                                                                            |
|----------------------|---------------------|-----------|----------------------------------------------------------------------------------------------|
| Tập dữ liệu          | Dataset             | D         | Tập hợp nhiều mẫu dữ liệu.                                                                   |
| Mô hình              | Model               | f         | Hàm hoặc cấu trúc ánh xạ đầu vào thành dự đoán.                                              |
| Tham số              | Parameter           | $\theta$  | Đại lượng của mô hình được học từ dữ liệu.                                                   |
| Dự đoán              | Prediction          | $\hat{y}$ | Kết quả do mô hình tạo ra.                                                                   |
| Hàm mất mát          | Loss function       | L         | Hàm đo mức độ sai của dự đoán cho một hoặc nhiều mẫu.                                        |
| Huấn luyện           | Training            | —         | Quá trình sử dụng dữ liệu để điều chỉnh tham số mô hình.                                     |
| Suy luận             | Inference           | —         | Dùng mô hình đã học để tạo dự đoán cho đầu vào.                                              |
| Siêu tham số         | Hyperparameter      | —         | Cấu hình do người dùng hoặc quy trình lựa chọn, không được học theo cùng cơ chế với tham số. |
| Tập huấn luyện       | Training set        | —         | Dữ liệu dùng trực tiếp để học tham số.                                                       |
| Tập kiểm định        | Validation set      | —         | Dữ liệu dùng để lựa chọn mô hình, siêu tham số hoặc ngưỡng.                                  |
| Tập kiểm tra         | Test set            | —         | Dữ liệu dành cho đánh giá cuối cùng sau quá trình lựa chọn.                                  |

## PHẦN 5 — VẤN ĐỀ MÀ THUẬT TOÁN GIẢI QUYẾT

Xét một ví dụ minh họa nhỏ: dự đoán điểm dựa trên số giờ học và số đề đã luyện. Các con số dưới đây chỉ để học cách biểu diễn dữ liệu, không phải kết quả nghiên cứu về học tập.

| Số giờ học | Số đề đã luyện | Điểm |
|------------|----------------|------|
| 1          | 0              | 45   |
| 2          | 1              | 55   |
| 3          | 1              | 65   |
| 4          | 2              | 80   |

Đầu vào của một mẫu có hai đặc trưng: số giờ học và số đề đã luyện. Đầu ra cần dự đoán là điểm. Vì đầu ra là một giá trị số liên tục trong ví dụ, đây là một bài toán hồi quy.

$$\mathbf{x} = [\mathbf{x}_1, \mathbf{x}_2]^T$$

Ở đây  $x_1$  là số giờ học,  $x_2$  là số đề đã luyện. Ký hiệu  $T$  chỉ việc hình dung vector theo dạng cột; trong NumPy, vector một chiều thường có shape (2,).

## PHẦN 6 — TRỰC GIÁC

Khi nhìn nhiều cặp “đầu vào → đáp án”, ta muốn tìm một quy luật có khả năng áp dụng cho dữ liệu chưa từng thấy. Máy tính không “cảm nhận” quy luật như con người; ta phải chỉ định một họ mô hình và một cách đo sai số. Quá trình huấn luyện tìm các tham số để mô hình tạo dự đoán có sai số phù hợp với mục tiêu tối ưu.

```
Đầu vào x
    ↓
Mô hình fθ
    ↓
Dự đoán ŷ
    ↓
So sánh với y
    ↓
Hàm mất mát
```

### NĂM CÂU HỎI PHẢI TRẢ LỜI

WHAT: mô hình là gì? WHY: vì sao cần học từ dữ liệu? HOW: mô hình biến đầu vào thành dự đoán như thế nào? WHEN: khi nào dạng bài toán này phù hợp? FAILURE: khi nào mô hình thất bại hoặc đánh giá sai?

## PHẦN 7 — MÔ HÌNH TOÁN HỌC

Giả sử có  $n$  mẫu và mỗi mẫu có  $d$  đặc trưng. Toàn bộ đầu vào được xếp thành ma trận  $X$ :

$$X \in \mathbb{R}^{n \times d}$$

$n$  = số mẫu.  $d$  = số đặc trưng. Mỗi hàng của  $X$  là một mẫu; mỗi cột là một đặc trưng.

$$X = [[1, 0], [2, 1], [3, 1], [4, 2]] \Rightarrow X \in \mathbb{R}^{4 \times 2}$$

Biến mục tiêu được xếp thành vector  $y$ :

$$y = [45, 55, 65, 80]^T$$

Mô hình tổng quát có thể ký hiệu:

$$\hat{y} = f_{\theta}(x)$$

$x$ : đầu vào của một mẫu.  $f$ : mô hình.  $\theta$ : tập tham số của mô hình.  $\hat{y}$ : dự đoán.

## PHẦN 8 — GIẢI THÍCH TỪNG CÔNG THỨC

### 8.1. Dự đoán

$$\hat{y} = f\theta(x)$$

- Công thức dùng để làm gì? Biểu diễn việc mô hình nhận đầu vào  $x$  và tạo dự đoán  $\hat{y}$ .
- Kích thước phụ thuộc bài toán. Nếu một mẫu có đặc trưng thì  $x$  có thể có shape  $(d,)$ .
- $\theta$  có thể là một số, một vector, nhiều vector hoặc nhiều ma trận tùy mô hình.
- Trong suy luận,  $\theta$  thường được giữ cố định.

### 8.2. Mất mát bình phương cho một mẫu

$$L(\hat{y}, y) = (\hat{y} - y)^2$$

- Công thức đo sai số của một dự đoán số. Sai số được bình phương nên dấu âm bị loại bỏ.
- Nếu  $\hat{y} = y$  thì mất mát bằng 0.
- Nếu độ lệch tuyệt đối tăng gấp đôi thì giá trị bình phương tăng gấp bốn.
- Đây chỉ là một hàm mất mát minh họa; không phải mọi bài toán đều dùng nó.

### 8.3. Mất mát trung bình trên $n$ mẫu

$$J(\theta) = (1/n) \cdot \sum_{i=1}^n L(f\theta(x^{(i)}), y^{(i)})$$

Công thức này mô tả một khung tối ưu hóa phổ biến: với mỗi mẫu  $i$ , mô hình tạo dự đoán, tính mất mát, cộng các mất mát rồi chia cho  $n$ . Không phải mọi thuật toán Học máy cổ điển đều được cài đặt bằng cách đạo hàm trực tiếp công thức này; cây quyết định là một ví dụ có cơ chế xây dựng khác.

## PHẦN 9 — SUY RA CÔNG THỨC

Ở bài nền tảng này, ta chưa suy ra Gradient Descent vì cần dạy đạo hàm và gradient một cách đầy đủ trước. Tuy nhiên, ta có thể suy ra công thức mất mát trung bình từ yêu cầu “đo mức lỗi điển hình trên mỗi mẫu”.

Giả sử bốn mẫu có mất mát lần lượt 0, 25, 25 và 25. Tổng mất mát là:

$$0 + 25 + 25 + 25 = 75$$

Có 4 mẫu nên mất mát trung bình là:

$$75 / 4 = 18.75$$

#### VÌ SAO CHIA CHO $n$ ?

Nếu chỉ dùng tổng, tập dữ liệu có nhiều mẫu hơn thường tạo tổng lớn hơn chỉ vì số lượng mẫu lớn. Lấy trung bình giúp diễn giải mức mất mát trung bình trên mỗi mẫu. Trong các bài sau, ta sẽ thấy một số tài liệu có hệ số  $1/(2n)$  cho tiện đạo hàm; khi đó phải giải thích rõ vì sao.

## PHẦN 10 — VÍ DỤ TÍNH BẰNG TAY

Xét mô hình minh họa đã có sẵn các hệ số:

$$\hat{y} = 10x_1 + 5x_2 + 35$$

Lưu ý: các hệ số 10, 5 và 35 được cho trước chỉ để học cách dữ liệu đi qua mô hình; ta chưa học cách huấn luyện chúng.

Với mẫu  $x = [2, 1]^T$  và giá trị thật  $y = 55$ :

1. Thay  $x_1 = 2$  và  $x_2 = 1$  vào mô hình:  $\hat{y} = 10 \cdot 2 + 5 \cdot 1 + 35$ .
2. Tính:  $\hat{y} = 20 + 5 + 35 = 60$ .
3. Sai số có dấu:  $\hat{y} - y = 60 - 55 = 5$ .
4. Mất mát bình phương:  $L = 5^2 = 25$ .

```
Input x
↓
Model fθ
↓
Prediction ŷ = 60
↓
Compare with y = 55
↓
Loss = 25
```

## PHẦN 11 — THUẬT TOÁN

Ở mức tổng quát, quy trình Học máy có giám sát có thể mô tả như sau.

### INPUT

Một tập dữ liệu gồm các đặc trưng  $X$  và biến mục tiêu  $y$ .

### OUTPUT

Một mô hình đã học có thể tạo dự đoán cho dữ liệu mới, kèm quy trình đánh giá phù hợp.

5. Xác định bài toán và biến mục tiêu.
6. Chọn các đặc trưng đầu vào hợp lệ.
7. Chia dữ liệu thành các phần phù hợp với chiến lược đánh giá.
8. Học các quy tắc tiền xử lý chỉ từ dữ liệu được phép dùng ở giai đoạn đó.
9. Chọn mô hình và cấu hình.
10. Huấn luyện mô hình trên tập huấn luyện.

11. Dùng tập kiểm định hoặc Cross-Validation để lựa chọn cấu hình nếu cần.
12. Khóa quy trình lựa chọn rồi đánh giá cuối trên tập kiểm tra.
13. Khi triển khai, áp dụng cùng preprocessing rồi mới suy luận.

## PHẦN 12 — PSEUDOCODE

```

INPUT: dataset D

Split D into training, validation, test

Fit preprocessing rules on training only
Transform training with learned preprocessing
Transform validation with the same preprocessing
Transform test with the same preprocessing

Choose model configuration
Train model on training data
Evaluate candidate settings on validation data
Select final configuration
Evaluate final model on test data

For a new sample:
    apply the learned preprocessing
    prediction = model(sample)

OUTPUT: prediction

```

Điểm quan trọng nhất: “fit preprocessing” và “transform” là hai hành động khác nhau. Ví dụ, khi chuẩn hóa bằng trung bình và độ lệch chuẩn, các đại lượng này phải được học từ tập huấn luyện, sau đó dùng lại để biến đổi tập kiểm định và tập kiểm tra.

## PHẦN 13 — ĐỘ PHỨC TẠP

Không có một độ phức tạp thời gian hoặc bộ nhớ duy nhất cho toàn bộ “Học máy cổ điển”. Hồi quy tuyến tính, phương pháp K láng giềng gần nhất, cây quyết định và máy vectơ hỗ trợ có chi phí rất khác nhau. Vì vậy tài liệu không đưa ra một công thức chung để gây hiểu nhầm. Độ phức tạp sẽ được phân tích ở từng thuật toán cụ thể.

## PHẦN 14 — CÀI ĐẶT TỪ ĐẦU

Bài này chưa huấn luyện một mô hình hoàn chỉnh. Mục tiêu của phần cài đặt từ đầu là biểu diễn dữ liệu và tự tính một dự đoán cùng mất mát để nhìn rõ cơ chế.

```

import numpy as np

# X có shape (4, 2): 4 mẫu, 2 đặc trưng
X = np.array([
    [1.0, 0.0],
    [2.0, 1.0],
    [3.0, 1.0],

```

```

    [4.0, 2.0]
])

# y có shape (4,)
y = np.array([45.0, 55.0, 65.0, 80.0])

# Mô hình minh họa:  $y_{\text{hat}} = 10x_1 + 5x_2 + 35$ 
def predict_one(x):
    return 10.0 * x[0] + 5.0 * x[1] + 35.0

def squared_loss(y_hat, y_true):
    return (y_hat - y_true) ** 2

x = X[1]          # [2.0, 1.0]
y_true = y[1]     # 55.0
y_hat = predict_one(x)
loss = squared_loss(y_hat, y_true)

print('X shape:', X.shape)
print('y shape:', y.shape)
print('prediction:', y_hat)
print('loss:', loss)

```

Kết quả mong đợi: prediction = 60.0 và loss = 25.0. Phần này là suy luận với tham số cho trước, chưa phải training.

## PHẦN 15 — CÀI ĐẶT BẰNG THƯ VIỆN

### [CHÍNH THỨC TRONG SYLLABUS]

Syllabus 2026 yêu cầu thực hành với NumPy, Pandas và scikit-learn. Trong bài này ta chỉ sử dụng thư viện cho thao tác dữ liệu và chia tập; chưa gọi một mô hình để tránh che mất cơ chế trước khi học thuật toán cụ thể.

```

import pandas as pd
from sklearn.model_selection import train_test_split

df = pd.DataFrame({
    'hours': [1, 2, 3, 4],
    'practice_tests': [0, 1, 1, 2],
    'score': [45, 55, 65, 80]
})

X = df[['hours', 'practice_tests']]
y = df['score']


X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.25,
    random_state=42
)

```

```
print(X_train.shape)
print(X_test.shape)
```

`train_test_split` chia các mảng hoặc bảng tương ứng thành tập huấn luyện và tập kiểm tra. `random_state` là một cách cố định trạng thái sinh số ngẫu nhiên để phép chia có thể tái lập trong các lần chạy. Hàm này không tự đảm bảo chiến lược chia là đúng cho mọi dạng dữ liệu; chuỗi thời gian, nhóm bệnh nhân, dữ liệu theo người dùng hoặc các cấu trúc phụ thuộc khác cần chiến lược riêng.

PHẦN 16 — THEO DÕI DỮ LIỆU QUA TOÀN BỘ THUẬT TOÁN




Ví dụ có 1000 mẫu và 5 đặc trưng: `X` có shape (1000, 5), `y` có shape (1000,). Nếu chia 800 mẫu huấn luyện, 100 mẫu kiểm định và 100 mẫu kiểm tra thì:

| Biến                      | Shape    | Ý nghĩa                      |
|---------------------------|----------|------------------------------|
| <code>X_train</code>      | (800, 5) | 800 mẫu, mỗi mẫu 5 đặc trưng |
| <code>y_train</code>      | (800,)   | 800 giá trị mục tiêu         |
| <code>X_validation</code> | (100, 5) | 100 mẫu kiểm định            |
| <code>y_validation</code> | (100,)   | 100 mục tiêu kiểm định       |
| <code>X_test</code>       | (100, 5) | 100 mẫu kiểm tra             |
| <code>y_test</code>       | (100,)   | 100 mục tiêu kiểm tra        |

# PHẦN 17 — HUẤN LUYỆN VÀ SUY LUẬN


## HUẤN LUYỆN

Trong huấn luyện, mô hình nhận dữ liệu huấn luyện và sử dụng tín hiệu mục tiêu để điều chỉnh các tham số theo thuật toán học. Điều cụ thể thay đổi tùy mô hình; ví dụ hồi quy tuyến tính có thể tối ưu một hàm mất mát, còn cây quyết định chọn các phép chia dữ liệu.



## SUY LUẬN

Trong suy luận, mô hình đã học nhận đầu vào mới và tạo dự đoán. Thông thường tham số không được cập nhật trong bước này.



# PHẦN 18 — CÁC SIÊU THAM SỐ

Không có một bộ siêu tham số chung cho mọi mô hình. Ví dụ:

| Mô hình                          | Ví dụ siêu tham số                     | Ý nghĩa khái quát                                                                                                 |
|----------------------------------|----------------------------------------|-------------------------------------------------------------------------------------------------------------------|
| K láng giềng gần nhất            | Số láng giềng                          | Quyết định bao nhiêu điểm lân cận tham gia dự đoán.                                                               |
| Cây quyết định                   | Độ sâu tối đa                          | Giới hạn mức độ phân nhánh của cây.                                                                               |
| Máy vectơ hỗ trợ                 | Độ mạnh điều chuẩn hoặc tham số kernel | Điều khiển cân bằng giữa biên phân tách, lỗi và hình dạng ranh giới.                                              |
| Quá trình huấn luyện mạng nơ-ron | Learning rate; batch size; số epoch    | Điều khiển quá trình tối ưu; đây thuộc chủ đề mạng nơ-ron, không phải siêu tham số chung cho mọi Học máy cổ điển. |

Tác động của việc tăng hoặc giảm siêu tham số phụ thuộc thuật toán và dữ liệu. Không nên học thuộc các câu kiểu “tăng luôn tốt hơn” hoặc “giảm luôn chống Overfitting”.

## PHẦN 19 — GIẢ ĐỊNH CỦA PHƯƠNG PHÁP

Bài 1 là khung chung nên không có một bộ giả định toán học duy nhất. Mỗi thuật toán sau này có giả định hoặc thiên kiến quy nạp riêng. Tuy nhiên, đánh giá mô hình luôn cần một giả định thực tế quan trọng: dữ liệu dùng để đánh giá phải đại diện hợp lý cho tình huống mà mô hình sẽ gặp.

### VÍ DỤ CHUỖI THỜI GIAN

Nếu mục tiêu là dùng quá khứ để dự đoán tương lai, việc trộn ngẫu nhiên mọi thời điểm rồi chia có thể tạo đánh giá không phản ánh tình huống triển khai. Khi đó cần chiến lược chia theo thời gian hoặc chiến lược phù hợp với cấu trúc dữ liệu.

## PHẦN 20 — ƯU ĐIỂM VÀ HẠN CHẾ

Không thể đánh giá chung “Học máy cổ điển là tốt” hoặc “Học sâu luôn tốt hơn”. Học máy cổ điển là một nhóm nhiều phương pháp với cơ chế khác nhau. Ưu điểm, hạn chế, yêu cầu dữ liệu, khả năng diễn giải và chi phí tính toán phải được phân tích theo từng thuật toán và bối cảnh.

| Khía cạnh  | Điều cần hỏi thay vì kết luận chung                                    |
|------------|------------------------------------------------------------------------|
| Dữ liệu    | Số mẫu bao nhiêu? Kiểu dữ liệu gì? Có thiếu dữ liệu không?             |
| Mục tiêu   | Hồi quy, phân loại, phân cụm hay giảm chiều?                           |
| Đánh giá   | Metric nào phản ánh đúng mục tiêu?                                     |
| Triển khai | Giới hạn thời gian, bộ nhớ, độ trễ và khả năng giải thích?             |
| Rủi ro     | Có Data Leakage, distribution shift hoặc nhóm dữ liệu phụ thuộc không? |

## PHẦN 21 — SO SÁNH VỚI PHƯƠNG PHÁP LIÊN QUAN

| Phương pháp | Điểm giống                       | Điểm khác                                                           | Khi nào phù hợp                          |
|-------------|----------------------------------|---------------------------------------------------------------------|------------------------------------------|
| Hồi quy     | Đều học từ dữ liệu có nhãn       | Đầu ra thường là giá trị số liên tục                                | Dự đoán đại lượng số                     |
| Phân loại   | Đều học từ dữ liệu có nhãn       | Đầu ra là lớp hoặc điểm số liên quan đến lớp                        | Nhận dạng nhóm/lớp                       |
| Phân cụm    | Đều dùng dữ liệu để tìm cấu trúc | Không cần nhãn đích theo thiết lập cơ bản                           | Khám phá nhóm trong dữ liệu              |
| Giảm chiều  | Đều biến đổi dữ liệu             | Mục tiêu là biểu diễn ít chiều hơn thay vì trực tiếp dự đoán target | Trực quan hóa, nén đặc trưng, tiền xử lý |

## PHẦN 22 — NHỮNG LỖI HỌC SINH RẤT DỄ MẮC

**Cho target vào X:** Ví dụ dự đoán “score” nhưng lại để cột score trong các đặc trưng. Đây là target leakage.

**Huấn luyện và kiểm tra trên cùng dữ liệu:** Điểm rất cao trên training không chứng minh khả năng tổng quát hóa.

**Dùng test để chọn mô hình:** Xem test liên tục rồi điều chỉnh mô hình khiến test tham gia vào quá trình lựa chọn.

**Fit preprocessing trước khi chia dữ liệu:** Trung bình, độ lệch chuẩn hoặc các thống kê khác có thể mang thông tin từ test sang training.

**Nhầm shape:** (1000, 2) thường nghĩa là 1000 mẫu  $\times$  2 đặc trưng; (2, 1000) là cấu trúc khác.

**Nhầm parameter và hyperparameter:** Parameter được học từ dữ liệu; hyperparameter là cấu hình lựa chọn bên ngoài cơ chế học tham số.

**Nhầm logits và probability:** Sẽ học kỹ ở bài phân loại; logits chưa phải xác suất nếu chưa qua biến đổi phù hợp.

**Dùng metric không phù hợp:** Accuracy có thể che giấu vấn đề khi dữ liệu mất cân bằng; phải chọn metric theo mục tiêu.

**Nhầm tương quan với nhân quả:** Dự đoán tốt không tự động chứng minh một biến gây ra biến khác.

## PHẦN 23 — GÓC NHÌN OLYMPIC

### [CHÍNH THỨC TRONG SYLLABUS]

International Olympiad in Artificial Intelligence 2026 phân loại rõ các mục Theory, Practice và Both. Với chủ đề Học máy cổ điển, thí sinh vừa phải hiểu cơ chế của một số thuật toán vừa phải biết gọi thư viện, xử lý dữ liệu và diễn giải kết quả. Syllabus cũng yêu cầu thực hành scikit-learn, NumPy, Pandas, chia train/validation/test, chuẩn hóa và xử lý dữ liệu.

International Artificial Intelligence Olympiad 2026 xác nhận ngày lý thuyết tập trung vào bài toán toán học hoặc thuật toán và ngày thực hành kiểm tra lập trình, xây dựng mô hình; trang chính thức xác nhận Python được dùng cho toàn bộ lập trình và mô hình hóa.

| Năng lực             | Bài 1 cần đạt                                                                               |
|----------------------|---------------------------------------------------------------------------------------------|
| A. Cần nhớ           | Ý nghĩa của sample, feature, target, parameter, hyperparameter, training, validation, test. |
| B. Cần hiểu          | Vì sao cần tách dữ liệu; vì sao test không được dùng để lựa chọn; Data Leakage là gì.       |
| C. Cần tính bằng tay | Shape; dự đoán đơn giản; sai số; mất mát bình phương; mất mát trung bình.                   |
| D. Cần lập trình     | Tạo mảng NumPy, DataFrame Pandas, tách X và y, chia train/test.                             |

| Năng lực             | Bài 1 cần đạt                                                          |
|----------------------|------------------------------------------------------------------------|
| E. Cần biết thư viện | np.array, DataFrame, train_test_split; chưa cần học model.fit ở bài 1. |

**TRUNG THỰC VỀ ĐỀ THI**

Các bài tập ở phần 24 là bài tự biên soạn để luyện kỹ năng. Tài liệu không khẳng định chúng đã xuất hiện trong đề chính thức.

## PHẦN 24 — BÀI TẬP LUYỆN TẬP

### MỨC 1 — CƠ BẢN

Câu 1. Cho ma trận  $X = [[2,5,7],[3,1,9],[4,8,6],[1,3,2]]$ . Hãy xác định số mẫu, số đặc trưng và shape của  $X$ .

Câu 2. Trong bài toán dự đoán giá nhà có các cột: diện tích, số phòng ngủ, tuổi căn nhà, giá bán. Hãy xác định features và target.

### MỨC 2 — VẬN DỤNG

Câu 3. Mô hình dự đoán  $\hat{y} = 72$  trong khi  $y = 75$ . Tính mất mát bình phương  $(\hat{y} - y)^2$ .

Câu 4. Bốn mẫu có mất mát lần lượt 1, 4, 9 và 16. Tính mất mát trung bình.

### MỨC 3 — NÂNG CAO

Câu 5. Một dataset có 5000 mẫu và 12 features. Shape của  $X$  là gì? Nếu lấy 1000 mẫu làm test thì shape của  $X_{\text{test}}$  là gì?

Câu 6. Một học sinh chuẩn hóa toàn bộ dataset rồi mới chia training và test. Hãy chỉ ra vấn đề và mô tả thứ tự đúng.

### MỨC 4 — PHONG CÁCH OLYMPIC

Câu 7. Dataset gồm patient\_id, age, blood\_pressure, diagnosis. Nhiệm vụ là dự đoán diagnosis. Một thí sinh dùng  $X = df[['patient_id', 'age', 'blood_pressure', 'diagnosis']]$ . Tìm ít nhất một lỗi nghiêm trọng và giải thích.

Câu 8. Một mô hình có training accuracy = 99.8% và test accuracy = 61.0%. Không được kết luận nguyên nhân duy nhất. Hãy nêu hiện tượng đáng nghi nhất và ít nhất hai thứ cần kiểm tra tiếp.

Câu 9. Dữ liệu gồm nhiều ảnh của cùng một người. Một học sinh chia ngẫu nhiên theo từng ảnh nên ảnh của cùng người có thể nằm ở cả training và test. Hãy phân tích vì sao đây có thể làm kết quả đánh giá quá lạc quan và đề xuất cách chia phù hợp hơn.

Câu 10. Một nhóm dùng tập test để thử 30 cấu hình và chọn cấu hình có test score cao nhất. Tại sao cách này làm mất ý nghĩa của test set? Nên thay bằng quy trình nào?

## PHẦN 25 — LỜI GIẢI

**Câu 1** — Có 4 hàng nên  $n = 4$ ; có 3 cột nên  $d = 3$ ;  $X$  có shape  $(4, 3)$ . Lỗi thường gặp: đảo hai chiều.

**Câu 2** — Features: diện tích, số phòng ngủ, tuổi căn nhà. Target: giá bán. Lỗi thường gặp: đưa giá bán vào  $X$ .

**Câu 3** —  $(72 - 75)^2 = (-3)^2 = 9$ .

**Câu 4** —  $(1 + 4 + 9 + 16) / 4 = 30/4 = 7.5$ .

**Câu 5** —  $X$  có shape  $(5000, 12)$ . Nếu test có 1000 mẫu thì  $X_{\text{test}}$  có shape  $(1000, 12)$ . Số đặc trưng không đổi chỉ vì ta chia dữ liệu.

**Câu 6** — Chuẩn hóa trước khi chia có thể làm thống kê từ test ảnh hưởng preprocessing. Quy trình đúng: chia trước  $\rightarrow$  fit preprocessing trên training  $\rightarrow$  transform training, validation và test bằng cùng các tham số đã học.

**Câu 7** — diagnosis là target nhưng bị đưa vào  $X$ , gây target leakage. patient\_id thường là mã định danh; có thể mang tín hiệu giả hoặc giúp mô hình ghi nhớ cá thể, nên cần xem xét thay vì mặc nhiên dùng.

**Câu 8** — Hiện tượng đáng nghi nhất là Overfitting hoặc chênh lệch phân phối, nhưng chưa thể kết luận nguyên nhân duy nhất. Cần kiểm tra cách chia, Data Leakage, preprocessing, kích thước dữ liệu, độ phức tạp mô hình và metric.

**Câu 9** — Nếu cùng một người xuất hiện ở cả training và test, mô hình có thể tận dụng đặc điểm cá nhân để làm tốt trên test thay vì tổng quát sang người mới. Nên chia theo người hoặc theo nhóm, sao cho toàn bộ dữ liệu của một người chỉ nằm trong một tập.

**Câu 10** — Thử 30 cấu hình trên test biến test thành dữ liệu lựa chọn. Nên chọn cấu hình bằng validation hoặc Cross-Validation, sau đó chỉ dùng test cho đánh giá cuối cùng.

## PHẦN 26 — KIỂM TRA MỨC ĐỘ HIỂU

14. Tại sao không nên đánh giá mô hình chỉ bằng training set?
15. Feature khác target ở điểm nào?
16. Nếu  $X$  có shape  $(200, 8)$ , số mẫu và số đặc trưng bằng bao nhiêu?
17. Parameter được học bằng cách nào về mặt khái niệm? Hyperparameter khác ở đâu?
18. Tại sao xem test score rồi tiếp tục điều chỉnh mô hình làm đánh giá bị thiên lệch?
19. Training khác inference ở điểm cốt lõi nào?
20. Nếu preprocessing dùng trung bình của test set, vấn đề gì xảy ra?
21. Tại sao train\_test\_split không tự động đúng cho dữ liệu chuỗi thời gian hoặc dữ liệu theo nhóm?
22. Một training score cao có đảm bảo test score cao không? Vì sao?

23. Trong pipeline  $X \rightarrow \text{model} \rightarrow \hat{y} \rightarrow \text{loss}$ , mỗi ký hiệu có vai trò gì?

#### TIÊU CHUẨN TỰ ĐÁNH GIÁ

Nếu chưa thể trả lời ít nhất 8/10 câu bằng lời của chính mình, nên ôn lại các phần 4, 7, 16, 17 và 22 trước khi chuyển sang Hồi quy tuyến tính.

## PHẦN 27 — TÓM TẮT CUỐI BÀI

### A. 10 điều quan trọng nhất

- Dataset gồm nhiều samples; mỗi sample được mô tả bởi một hoặc nhiều features.
- Học máy có giám sát sử dụng target để học quy luật dự đoán.
- Hồi quy dự đoán đại lượng số; phân loại dự đoán lớp hoặc đại lượng liên quan đến lớp.
- X thường có shape (number\_of\_samples, number\_of\_features).
- Model ánh xạ input thành prediction.
- Loss đo mức sai; metric đánh giá chất lượng theo mục tiêu cụ thể.
- Training dùng dữ liệu để học parameter; inference dùng model đã học để dự đoán.
- Hyperparameter là cấu hình bên ngoài quá trình học parameter.
- Validation dùng cho lựa chọn; test dùng cho đánh giá cuối.
- Data Leakage có thể làm kết quả nhìn tốt hơn thực tế.

### B. Công thức phải nhớ

$$X \in \mathbb{R}^{n \times d}$$

$$\hat{y} = f\theta(x)$$

$$L(\hat{y}, y) = (\hat{y} - y)^2$$

$$J(\theta) = (1/n) \cdot \sum_{i=1}^n L(f\theta(x^{(i)}), y^{(i)})$$

### C. Khái niệm phải hiểu

sample, feature, target, model, parameter, hyperparameter, training, inference, loss, training set, validation set, test set, Data Leakage.

### D. Code phải biết

```
X.shape
X[:, 0]
df[['feature_1', 'feature_2']]
df['target']
train_test_split(...)
```

E. Những phần không cần học thuộc

Không cần học thuộc các số trong ví dụ, tên biến hoặc thứ tự dòng code. Cần hiểu cấu trúc dữ liệu, ý nghĩa phép tính và lý do của từng bước.

PHẦN 28 — BẢN ĐỒ LIÊN KẾT KIẾN THỨC

| Vị trí        | Nội dung                                                                                                  | Vì sao                                                                                                         |
|---------------|-----------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------|
| Bài trước     | Python cơ bản → NumPy → Pandas                                                                            | Cung cấp công cụ biểu diễn và thao tác dữ liệu.                                                                |
| Bài hiện tại  | Dữ liệu → đặc trưng → target → model<br>→ prediction → loss → training →<br>validation → test → inference | Xây khung tư duy chung cho mọi mô hình sau.                                                                    |
| Bài tiếp theo | Hồi quy tuyến tính                                                                                        | Là mô hình đầu tiên đủ đơn giản để suy ra công thức, tính bằng tay, học Gradient Descent và triển khai từ đầu. |

BÀI TIẾP THEO

Bài 2 sẽ bắt đầu từ  $y = wx + b$ , xây dựng Mean Squared Error, dạy đạo hàm từ nền tảng, giải thích gradient, suy ra công thức cập nhật, tính tay từng bước, cài đặt Python thuần, NumPy, rồi mới dùng LinearRegression của scikit-learn.

PHẦN 29 — TÀI LIỆU THAM KHẢO ĐÃ THỰC SỰ SỬ DỤNG

1. International Olympiad in Artificial Intelligence 2026 Syllabus

**Tổ chức/Tác giả:** International Olympiad in Artificial Intelligence — International Scientific Committee

**Năm:** 2026

**Phần đã dùng:** Foundational Skills & Classical Machine Learning; Topic Classifications

**Đường dẫn:** <https://ioai-official.org/wp-content/uploads/2025/10/Syllabus.pdf>

**Nguồn này được dùng để xác nhận:** Xác nhận phạm vi chính thức, phân loại Theory / Practice / Both, các thuật toán và nội dung xử lý dữ liệu.

2. Syllabus — International Olympiad in Artificial Intelligence

**Tổ chức/Tác giả:** International Olympiad in Artificial Intelligence

**Năm:** 2026

**Phần đã dùng:** Trang syllabus chính thức

**Đường dẫn:** <https://ioai-official.org/republic-of-kazakhstan/syllabus-2026/>

**Nguồn này được dùng để xác nhận:** Xác nhận cơ chế phân loại Theory, Practice, Both và liên kết đến syllabus chính thức.

3. Competition 2026

**Tổ chức/Tác giả:** International Artificial Intelligence Olympiad

**Năm:** 2026

**Phần đã dùng:** Supervised Learning; Unsupervised Learning; Evaluation of Machine Learning Models; Frequently Asked Questions

**Đường dẫn:** <https://iaio-official.org/competition2026/>

**Nguồn này được dùng để xác nhận:** Đối chiếu các chủ đề Học máy cổ điển và xác nhận toán học, lập trình, mô hình hóa bằng Python.

#### 4. Olympic Trí tuệ nhân tạo Việt Nam — International Artificial Intelligence Olympiad 2027 Việt Nam

**Tổ chức/Tác giả:** Ban tổ chức tại Việt Nam

**Năm:** 2026

**Phần đã dùng:** Thông tin tuyển chọn 2026 và kỳ thi 2027

**Đường dẫn:** <https://iaio.vn/vi/>

**Nguồn này được dùng để xác nhận:** Xác nhận kỳ tuyển chọn Việt Nam 2026 hướng tới chọn 8 học sinh dự kỳ thi quốc tế năm 2027 tại Đà Nẵng.

#### 5. NumPy documentation — The N-dimensional array

**Tổ chức/Tác giả:** NumPy Developers

**Năm:** Tài liệu hiện hành

**Phần đã dùng:** ndarray và shape

**Đường dẫn:** <https://numpy.org/doc/stable/reference/arrays.ndarray.html>

**Nguồn này được dùng để xác nhận:** Xác nhận ý nghĩa mảng nhiều chiều và shape.

#### 6. pandas documentation — DataFrame

**Tổ chức/Tác giả:** pandas Developers

**Năm:** Tài liệu hiện hành

**Phần đã dùng:** DataFrame

**Đường dẫn:** <https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.html>

**Nguồn này được dùng để xác nhận:** Xác nhận cấu trúc bảng hai chiều được gắn nhãn.

#### 7. scikit-learn documentation — train\_test\_split

**Tổ chức/Tác giả:** scikit-learn Developers

**Năm:** Tài liệu hiện hành

**Phần đã dùng:** `sklearn.model_selection.train_test_split`

**Đường dẫn:**

[https://scikit-learn.org/stable/modules/generated/sklearn.model\\_selection.train\\_test\\_split.html](https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html)

**Nguồn này được dùng để xác nhận:** Xác nhận mục đích, input/output và `random_state` của `train_test_split`.

#### 8. scikit-learn documentation — Common pitfalls and recommended practices

**Tổ chức/Tác giả:** scikit-learn Developers

**Năm:** Tài liệu hiện hành

**Phần đã dùng:** Inconsistent preprocessing; Data Leakage

**Đường dẫn:** [https://scikit-learn.org/stable/common\\_pitfalls.html](https://scikit-learn.org/stable/common_pitfalls.html)

**Nguồn này được dùng để xác nhận:** Xác nhận rủi ro Data Leakage và nguyên tắc fit preprocessing trên dữ liệu huấn luyện.

#### 9. CS229: Machine Learning

**Tổ chức/Tác giả:** Stanford University

**Năm:** Tài liệu khóa học hiện hành

**Phần đã dùng:** Supervised Learning; Linear Regression

**Đường dẫn:** <https://cs229.stanford.edu/>

**Nguồn này được dùng để xác nhận:** Đối chiếu cách tổ chức nền tảng học có giám sát trước khi vào Hồi quy tuyến tính.

#### KIỂM TRA CHẤT LƯỢNG

Tài liệu đã tách rõ kiến thức chính thức trong syllabus và kiến thức nền; không gán bài tự tạo là đề thi thật; mọi ký hiệu cốt lõi được định nghĩa trước khi dùng; shape của dữ liệu được theo dõi; huấn luyện và suy luận được phân biệt; các ví dụ số được kiểm tra lại.